

**Implementación de algoritmos de inteligencia artificial para el análisis de la
relación entre el cerebro y corazón durante la anestesia mediante señales
fisiológicas**



Universidad
del Cauca

Estudiante

Marlen Sofia Muñoz Ruiz

Universidad del Cauca
Facultad de Ciencias Naturales, Exactas y de la Educación
Departamento de Física
Popayán
2024

Implementación de algoritmos de inteligencia artificial para el análisis de la relación entre el cerebro y corazón durante la anestesia mediante señales fisiológicas

Este texto es el resultado del Trabajo de Grado, modalidad trabajo de Investigación, como requisito parcial para optar al título Ingeniera Física

Marlen Sofia Muñoz Ruiz

Director

Rubiel Vargas Cañas PhD.

Departamento de física, Universidad del Cauca

Co-Director

Ennio Idrobo Ávila PhD.

Facultad de Informática Aplicada, Universidad de Augsburg

Universidad del Cauca

Facultad de Ciencias Naturales, Exactas y de la Educación

Departamento de Física

Popayán

2024

Nota de aceptación:

Aprobado



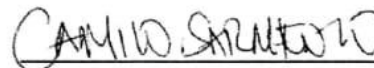
Rubiel Vargas Cañas PhD.

DIRECTOR



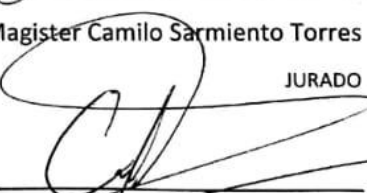
Ennio Idrobo Ávila PhD.

CODIRECTOR



Magister Camilo Sarmiento Torres

JURADO



Magister Carlos Felipe Ordoñez

JURADO

Fecha de sustentación: 05 de septiembre de 2024

AGRADECIMIENTOS

La autora de este documento expresa el más sincero agradecimiento a todas las personas que contribuyeron al desarrollo de este trabajo, en especial a la familia y compañeros, pero sobre todo al Ennio Idrobo Ávila PhD. por orientar esta investigación, al Rubiel Vargas Cañas PhD., y por supuesto a la Universidad del Cauca.

RESUMEN

En este documento se presenta el procedimiento para analizar la relación entre el cerebro y el corazón durante la anestesia mediante algoritmos de inteligencia artificial y modelos computacionales. Fisiológicamente, estos dos órganos están interconectados a través de complejas conexiones, su comprensión ha permitido el entendimiento de varios mecanismos relacionados con afecciones neurológicas y cardíacas. Desde el punto de vista de la anestesia, el estudio de esta relación podría ser crucial para mitigar algunos de los desafíos que enfrentan los anestesiólogos diariamente, como el tomar decisiones rápidas, evaluar la salud del paciente, ajustar la anestesia y anticipar posibles complicaciones, garantizando la seguridad y bienestar del paciente.

La metodología propuesta se centró en el uso de algoritmos de clasificación como una herramienta para observar el comportamiento del cerebro y el corazón en diferentes estados de anestesia: despierto, sedación moderada, anestesia general y anestesia profunda. Para clasificar estos estados, se extrajeron características de señales de electroencefalograma (EEG) y electrocardiograma (ECG), analizadas en diferentes bandas de frecuencia. Para asegurar la robustez de la clasificación, se implementó un método de clasificación por votos que combina varios algoritmos y se emplearon técnicas de validación cruzada estratificada, realizando la clasificación tanto de manera independiente como dependiente del paciente.

La clasificación de los estados se llevó a cabo de tres formas, teniendo en cuenta: información proveniente del cerebro, proveniente del corazón y de ambos órganos. Los mejores resultados, se obtuvieron al emplear características extraídas de las señales de ambos órganos. En particular, mostraron que los diferentes estados de anestesia podían ser clasificadas con mayor precisión, lo que sugirió que ambos órganos varían dependiendo del estado y, por lo tanto, la relación entre ellos.

Posteriormente, para validar lo descrito, se aplicaron técnicas que permitieron analizar la dependencia entre los dos órganos, como el análisis de interdependencia no lineal (NI) y la información mutua (MI) entre las señales EEG y ECG. Con dicha información se clasificaron los estados de anestesia y se comprobó que la relación cerebro-corazón varía según el estado de la anestesia. Adicionalmente, se observó que la dependencia entre ambos órganos puede variar entre pacientes, posiblemente debido a distintas condiciones presentes antes, durante y después de la anestesia y cirugía.

Palabras Clave

Electroencefalograma, electrocardiograma, cerebro, corazón, anestesia, clasificación, interdependencia no lineal, información mutua.

TABLA DE CONTENIDO

1	INTRODUCCIÓN	13
1.1	Planteamiento del problema.....	13
1.2	Pregunta de investigación	14
1.3	Hipótesis	14
1.4	Objetivos.....	14
1.4.1	Objetivo General.....	14
1.4.2	Objetivos Específicos	15
1.5	Descripción de la metodología	15
1.5.1	Entendimiento del problema	15
1.5.2	Comprensión de los datos	16
1.5.3	Preparación de los datos	16
1.5.4	Modelado	16
1.5.5	Evaluación.....	16
1.6	Contribuciones.....	16
1.7	Estructura del documento.....	17
2	MARCO TEÓRICO	18
2.1	Marco Conceptual	18
2.1.1	Anestesia	18
2.1.2	Señales fisiológicas	21
2.1.2.1	Sistema Cardiovascular y electrocardiograma	22
2.1.2.2	Sistema nervioso y electroencefalograma	21
2.1.3	Relación cerebro - corazón.....	22
2.1.4	Inteligencia artificial	26
2.2	Marco Referencial	27
2.2.1	Referencias sobre análisis de coherencia.....	27
2.2.2	Referencias sobre análisis de correlación	28
2.2.3	Referencias sobre análisis de interacción	30
2.3	Análisis de la literatura	31
	Tabla comparativa	31

3	METODOLOGÍA.....	34
3.1	Comprensión de los datos	34
3.1.1	Recolección de los datos	34
3.1.2	Descripción de los datos.....	35
3.1.3	Exploración de los datos.....	35
3.1.4	Verificar la calidad de los datos.....	36
3.2	Preparación de los datos	36
3.2.1	Selección de los datos	36
3.2.2	Preprocesamiento de las señales	37
3.2.2.1	Preprocesamiento de las señales EEG y ECG	38
3.2.2.2	Preprocesamiento de la señal BIS	39
3.2.2.3	Obtención de VFC.....	39
3.2.2.4	Descomposición de las señales	41
3.2.3	Extracción de características	41
3.2.3.1	Características Estadísticas.....	41
3.2.3.2	Características caóticas	43
3.2.3.3	Características basadas en entropía.....	43
3.2.3.4	Características extraídas de la VFC.....	44
3.2.4	Obtención del DataFrame	46
3.2.4.1	Ajuste de los datos	46
3.2.4.2	Selección de características.....	47
3.3	Modelado	48
3.3.1	Selección de técnicas de modelado	48
3.3.2	Generación del plan de pruebas	48
3.3.3	Construcción del modelo.....	49
3.3.4	Evaluación del modelo	49
3.4	Evaluación.....	50
3.4.1	Teoría de la información mutua	51
3.4.2	Interdependencia no lineal.....	51
4	RESULTADOS Y ANÁLISIS	53
4.1	Comprensión de los datos	53

4.1.1	Recolección de los datos	53
4.1.2	Descripción de los datos.....	55
4.1.3	Exploración de los datos.....	56
4.1.4	Verificación de la calidad de los datos	59
4.2	Preparación de los datos	61
4.2.1	Selección de los datos	61
4.2.2	Preprocesamiento de las señales	62
4.2.2.1	Preprocesamiento de las señales EEG y ECG	62
4.2.2.2	Preprocesamiento de la señal BIS	63
4.2.2.3	Obtención de la VFC	64
4.2.2.4	Descomposición de las señales	66
4.2.3	Extracción de características	67
4.2.4	Obtención del dataframe	68
4.2.4.1	Ajuste de los datos	69
4.2.4.2	Selección de características.....	69
4.3	Modelado	73
4.3.1	Resultados del modelo de clasificación.....	73
4.3.2	Análisis general de los resultados obtenidos:	79
4.4	Evaluación.....	81
4.4.1	Interdependencia no lineal (N).....	81
4.4.2	Teoría de la información mutua	83
5	CONCLUSIONES Y TRABAJO FUTURO	85
6	REFERENCIAS	87

ÍNDICE DE TABLAS

Tabla 1. Resumen de las investigaciones realizadas sobre la relación entre el cerebro y corazón.	32
Tabla 2. Descripción general del grupo de pacientes a investigar.....	37
Tabla 3. Etiqueta de los estados del paciente.....	48
Tabla 4. Parámetros utilizados para la búsqueda por grilla.....	49
Tabla 5. Descripción general de la base de datos.....	53
Tabla 6. Descripción específica de los parámetros registrados en la base de datos.....	53
Tabla 7. Dispositivos utilizados para grabar las señales EEG, BIS y ECG.....	54
Tabla 8. Parámetros encontrados en el DataFrame de información clínica.....	55
Tabla 9. Visualización del DataFrame de parámetros hemodinámicos.....	56
Tabla 10. Descripción del DataFrame	56
Tabla 11. Descripción estadística de los datos demográficos de los 3232 pacientes.....	58
Tabla 12. Resultados del análisis de los DataFrame.....	60
Tabla 13. Características extraídas a las señales EEG, ECG y VFC.....	67
Tabla 14. Descripción general del DataFrame final obtenido.....	68
Tabla 15. Información adicional sobre el Dataframe.....	69
Tabla 16. Parámetros obtenidos con la búsqueda por grilla para los clasificadores seleccionados para las señales EEG (canal uno y dos).	74
Tabla 17. Resultados de la evaluación de la clasificación grupo 1.....	74
Tabla 18. Reporte de clasificación por cada una de las clases.....	75
Tabla 19. Resultados de la evaluación del grupo 2.....	75
Tabla 20. Reporte de clasificación por clase del grupo 2.....	76
Tabla 21. Resultados de la evaluación del ECG y VFC.....	76
Tabla 22. Reporte de la evaluación de la clasificación por clase, sin utilizar SGKF.....	77
Tabla 23. Reporte de clasificación por clase del grupo 3, utilizando SGKF.....	77
Tabla 24. Resultados de la evaluación del grupo 4.....	78
Tabla 25. Reporte de clasificación utilizando SGKF.....	78
Tabla 26. Combinaciones de señales y sus representaciones para el análisis de NI y MI. ..	81
Tabla 27. Valores de la mediana de NI entre diferentes combinaciones de señales	82
Tabla 28. Valores de la mediana de la teoría de la información mutua entre diferentes estados.....	84
Tabla 29. Resultados de la evaluación de la clasificación considerando datos de IM y NI..	84
Tabla 30. Reporte de clasificación por cada una de las clases.....	85

ÍNDICE DE FIGURAS

Figura 1. Ciclo de la metodología CRISP – DM.	15
Figura 2. Mecanismos neurofisiológicos de las acciones del Propofol y Sevoflurano en el cerebro [16].	19
Figura 3. Anteriorización de las ondas Alfa [16].	19
Figura 4. Comunicación entre el tálamo y la corteza [16].	20
Figura 5. Uso de monitorización del índice biespectral para medir la profundidad de la sedación/analgesia [17].	20
Figura 6. Diferentes tipos de ondas cerebrales [21].	22
Figura 7. Ritmo normal del corazón [24].	23
Figura 8. Descripción de los diferentes tipos de ondas en un electrocardiograma [24].	24
Figura 9. Las vías de comunicación neurales que interactúan entre el corazón y el cerebro [25].	25
Figura 10. Subcampos de la IA.	26
Figura 11. Interfaz de la base de datos.	35
Figura 12. Procedimiento realizado para la selección de características más importantes	48
Figura 13. Procedimiento propuesto para el análisis de la relación cerebro-corazón (MI: información mutua, NI: Interdependencia no lineal)	51
Figura 14. Análisis mediante box plot de algunas características de VFC: a) media de los intervalos RR (mean nni), b) desviación estándar del intervalo de tiempo entre latidos cardíacos normales sucesivos (sdsd), c) desviación estándar de las diferencias entre intervalos RR adyacentes (sdsd).	57
Figura 15. análisis mediante box plot de algunas características del canal 1 de la señal EEG: a) entropía de muestra (SampEn), b) entropía espectral (SE), c) Entropía de descomposición de valores singulares (SVD)	57
Figura 16. Análisis mediante box plots de algunas características del canal 2 de la señal EEG: a) varianza, b) std, c) vurtosis.	58
Figura 17. Distribución de Pacientes por: a) edad, b) peso, c) altura, d) tipo o sitio quirúrgico, e) ASA.	59
Figura 18. Segmento de buena calidad obtenido de la señal BIS.	60
Figura 19. Segmento de mala calidad obtenido de la señal BIS.	60
Figura 20. Segmento de buena calidad obtenido de la señal EEG canal dos.	61
Figura 21. Segmento de mala calidad obtenido de la señal EEG canal dos.	61
Figura 22. Segmento de buena calidad obtenido de la señal ECG.	61
Figura 23. Segmento de mala calidad obtenido de la señal ECG.	61
Figura 24. Selección de segmentos de buena calidad.	62
Figura 25. a) Espectro de frecuencias de la señal EEG con ruido de 60 Hz, b) Espectro de frecuencias de la señal EEG después de eliminar el ruido de 60 Hz.	63

Figura 26. Eliminación del ruido de bajas frecuencias a) Segmento de la señal EEG sin el suavizado, b) Segmento de la señal EEG con el suavizado.....	63
Figura 27. Segmento de la señal BIS a) sin procesar, b) después del procesamiento	63
Figura 28. Comparación entre una señal ECG con línea de base (superior) y después de la corrección de la línea de base (inferior).....	64
Figura 29. Segmento de la señal ECG, resaltando el complejo QRS.	64
Figura 30. Detección de los picos R en la señal ECG.	64
Figura 31. TCG obtenido después de detectar los picos R en la señal ECG.	65
Figura 32. Ejemplo de latido extra.	65
Figura 33. Ejemplo de cuando no se detecta un pico R.	66
Figura 34. Ejemplo de latido ectópico.....	66
Figura 35. Descomposición de las señales en diferentes bandas de frecuencia.	67
Figura 36. Identificación de valores atípicos a) datos de varianza sin eliminar valores atípicos, b) datos de varianza después de eliminar valores atípicos.	69
Figura 37. Distribución de las señales en bandas de frecuencia del EEG (canal uno).	70
Figura 38. Tipos de características más relevantes obtenidas con el grupo 1.....	71
Figura 39. Distribución de las señales en Bandas de frecuencia del EEG (canal dos).....	71
Figura 40. Tipos de características más relevantes obtenidas con el grupo 2.....	72
Figura 41. Distribución de las señales en bandas de frecuencia del ECG y VFC.	72
Figura 42. Tipos de características más relevantes obtenidas con el grupo 3.....	73
Figura 43. Representación del SGKF [50].	73
Figura 44. Matriz de confusión para la clasificación de los datos provenientes del grupo 1.	75
Figura 45. Matriz de confusión para la clasificación de los datos provenientes del grupo 2.	76
Figura 46. Matriz de confusión sin SGKF del grupo 3.....	77
Figura 47. Matriz de confusión utilizando SGKF.	78
Figura 48. Matriz de confusión del grupo 4.	79
Figura 49. Variación de la NI con a) diferentes valores de m , b) diferentes valores de τ , c) con diferentes valores de k	81
Figura 50. Variación de la interdependencia no lineal entre corazón y cerebro en diferentes pacientes. a) Ejemplo donde la interdependencia $N(X Y)$ (corazón-cerebro) es mayor y se mantiene estable en el tiempo. b) Ejemplo donde los valores de interdependencia fluctúan, mostrando cambios en la dirección de la dominancia entre cerebro y corazón.	83
Figura 51. Matriz de confusión de la clasificación considerando datos de IM y NI.....	85

LISTA DE ABREVIATURAS

<i>ECG</i>	Electrocardiograma
<i>EEG</i>	Electroencefalograma
<i>BIS</i>	Bispectral Index (índice bispectral)
<i>TCG</i>	Tacograma
<i>VFC</i>	Variabilidad de la frecuencia cardiaca
<i>SNA</i>	Sistema nervioso autónomo
<i>LOC</i>	Perdida de conocimiento
<i>ROC</i>	Recuperación de la conciencia
<i>CRISP-DM</i>	Cross Industry Standard Process of Data Mining
<i>SC</i>	Sistema cardiovascular
<i>SNCE</i>	Sistema nervioso cardiaco extrínseco
<i>SNCI</i>	Sistema nervioso cardiaco intrínseco
<i>SN</i>	Sistema nervioso
<i>SNC</i>	Sistema nervioso central
<i>SNS</i>	Sistema nervioso somático
<i>SNS</i>	Sistema nervioso simpático
<i>SNP</i>	Sistema nervioso parasimpático
<i>IA</i>	Inteligencia artificial
<i>ML</i>	Machine learning (Aprendizaje automático)
<i>DL</i>	Deep learning (aprendizaje profundo)
<i>MSC</i>	Squared Magnitude Coherence (coherencia de magnitud al cuadrado)
<i>CCF</i>	Cross-Correlation Function (función de correlación cruzada)
<i>CPSD</i>	Cross Power Spectral Density (densidad espectral de potencia cruzada)
<i>SGKF</i>	StratifiedGroupKFold
<i>SKF</i>	StratifiedKFold
<i>Std</i>	Standar Desviation (Desviación estándar)
<i>RMS - espectro</i>	
<i>Acc</i>	Accuracy (Exactitud)
<i>AUC</i>	Area under curve (área bajo la curva)
<i>CKC</i>	Cohen's kappa coefficient (Coeficiente kappa de Cohen)
<i>MI</i>	Mutual information (Información mutua)
<i>NI</i>	Non-linear interdependence (Intederpendecia no lineal)

CAPÍTULO 1

1 INTRODUCCIÓN

1.1 Planteamiento del problema

El cerebro y el corazón se conectan fisiológicamente a través del sistema nervioso autónomo (SNA), que es fundamental para la regulación de diversas funciones vitales. Esta conexión, se caracteriza por una compleja red de interconexiones que permiten interacción continua y bidireccional, influyendo activamente el uno en el otro [1]. El conocimiento acerca de esta relación se ha hecho cada vez más importante a medida que se comprenden mejor los mecanismos mutuos subyacentes. Esto ha hecho camino en el ámbito clínico, como por ejemplo, para abordar trastornos neurológicos y cardíacos de manera efectiva [2].

En el campo de la anestesia, se ha estudiado esta relación para el estudio de los procesos neuronales que sustentan las alteraciones del nivel de conciencia [3], [4]. Sin embargo, en la literatura, Emery Brown[5], uno de los pioneros en investigar lo que sucede en el cerebro bajo la anestesia, resalta que se necesitan conocimientos más prácticos sobre el proceso antes, durante y después de la anestesia. Desde el punto de vista del anestesiólogo, presentan retos significativos día a día, ya que deben tomar decisiones rápidas, evaluar la salud del paciente, ajustar la anestesia y anticipar posibles complicaciones [6].

Lo anterior, podría implicar, el estudio de la relación cerebro – corazón como una herramienta valiosa para la monitorización, detección de complicaciones, optimización y predicción de la recuperación, que contribuya a una atención más segura y personalizada para los pacientes. La relación dinámica entre el cerebro y el corazón durante la anestesia podría ayudar a los anestesiólogos a ajustar y optimizar la administración de los anestésicos para mantener un equilibrio adecuado entre la profundidad de la anestesia y la estabilidad hemodinámica del paciente. Adicionalmente, podría utilizarse para detectar eficientemente algunas complicaciones que afectan directamente el estado del paciente como por ejemplo, algunas deficiencias cognitivas u otras enfermedades cardíacas [7]. Asimismo, se podría obtener información sobre la recuperación del paciente después del procedimiento quirúrgico, ya que cambios en esa relación podrían ser indicativos de cambios de la función cardiovascular y neurológica del paciente después del

procedimiento quirúrgico. Lo anterior, podría ser de gran impacto, ya que anualmente aproximadamente 230 millones de personas reciben anestesia en todo el mundo [8].

Debido a las ventajas que puede traer esta comprensión, diversos campos multidisciplinarios se han encargado de abordar temas relacionados con el cerebro y corazón, generalmente en estudios relacionados con el sueño [9], [10], para observar cómo es dicha relación durante diferentes etapas o afecciones del sueño. También se ha analizado como cambia antes y después de un ataque epiléptico [11]. Sin embargo, se plantea que la interpretación de los cambios dinámicos de las bioseñales y sus relaciones tanto con parámetros primarios como secundarios, durante la anestesia, es una tarea compleja, incluso para anestesiólogos con experiencia [12]. En este caso, es desafiante la forma como se puede integrar la información proveniente del cerebro y corazón, porque presentan bastantes cambios frente a diversos estímulos producidos durante la anestesia [4].

En este sentido, los estudios que se centran en obtener información de la relación de dichos órganos no han considerado suficientes datos en cuanto a la cantidad de pacientes [4], [10]. También se observó que la composición de género no es equilibrada, no se han realizado estudios que consideren diferentes tipos de anestésicos [4], ni diferentes tipos de cirugía, no se han tenido en cuenta otros parámetros y bioseñales que varían durante la anestesia, que pueden ser importantes para estudiar dicha relación. Adicionalmente, tampoco se han implementado algoritmos de inteligencia artificial (IA), que pueden ser útiles para analizar y comprender dicha relación.

1.2 Pregunta de investigación

En relación con lo anterior, se plantea la siguiente pregunta de investigación: *¿Cómo evaluar la relación entre el cerebro y corazón durante la anestesia a través de señales fisiológicas, aplicando algoritmos de inteligencia artificial?*

1.3 Hipótesis

Los cambios en la actividad eléctrica de los órganos asociados (cerebro y corazón) durante los diferentes estados de la anestesia pueden ser diferenciados mediante algoritmos de inteligencia artificial (IA), que podrían proporcionar evidencia de la variación en la relación entre ambos órganos en estos estados.

1.4 Objetivos

1.4.1 Objetivo General

Implementar un modelo computacional que permita determinar la relación cerebro-corazón a través de señales fisiológicas asociadas durante la anestesia.

1.4.2 Objetivos Específicos

1. Identificar cómo se comportan las señales fisiológicas del corazón y cerebro durante la anestesia a través de la inspección de la literatura científica.
2. Analizar algoritmos computacionales que permitan procesar y posteriormente relacionar los cambios dinámicos de las señales fisiológicas tanto del corazón como del cerebro usando datos consignados en base de datos públicas.
3. Estimar el desempeño de los algoritmos empleando métricas de aprendizaje automático.

1.5 Descripción de la metodología

En este trabajo se implementó la metodología CRISP-DM (Cross Industry Standard Process of Data Mining), que permite planificar el desarrollo de un proyecto de ciencia de datos a partir de seis etapas: comprensión del problema, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue [13].

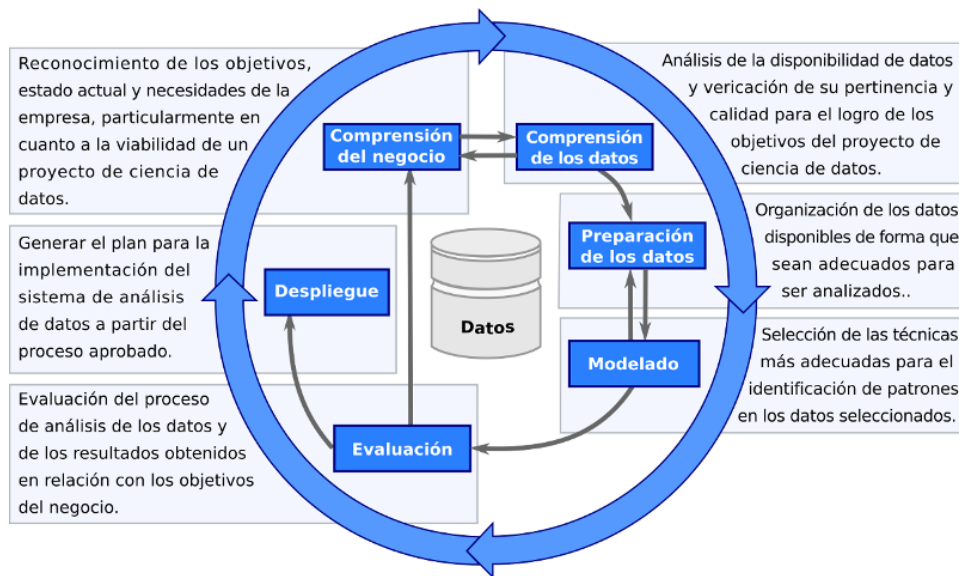


Figura 1. Ciclo de la metodología CRISP – DM [13].

Para esta investigación se consideraron cinco de las seis etapas de la metodología, que implicaron lo siguiente:

1.5.1 Entendimiento del problema

En esta etapa se llevó a cabo una revisión bibliográfica para estudiar y comprender la relación cerebro-corazón, su importancia y todo lo que puede implicar durante diferentes estados de la anestesia. Adicionalmente, se investigaron las técnicas implementadas para medir dicha relación y se estableció un plan de trabajo.

1.5.2 Comprensión de los datos

En esta etapa, se exploró la base de datos *VitalDB* con el fin de familiarizarse con la información y así conocer con qué tipo de variables se cuenta, verificar la calidad de los datos, pertinencia y cuáles de ellos son de mayor interés.

1.5.3 Preparación de los datos

Luego de comprender la base de datos, se seleccionó un conjunto de pacientes a evaluar, junto con las señales pertinentes, y se depuró la información para optimizar los resultados del análisis de la relación cerebro-corazón.

1.5.4 Modelado

En esta etapa se implementaron algoritmos de clasificación que fueron evaluados con diferentes métricas, para extraer información de la actividad eléctrica del corazón y el cerebro durante diferentes etapas de la anestesia.

1.5.5 Evaluación

Finalmente, se aplicaron modelos computacionales para relacionar las señales fisiológicas y extraer información sobre la interacción entre el cerebro y el corazón, teniendo en cuenta la información obtenida por los modelos de clasificación. Asimismo, se llevó a cabo un análisis cualitativo comparando los resultados obtenidos con los reportados en la bibliografía, lo que permitió identificar posibles mejoras para futuros trabajos.

1.6 Contribuciones

La principal contribución de este trabajo es la implementación de modelos de clasificación. Estos permitieron, no solo clasificar los diferentes estados del paciente considerando características del corazón y del cerebro, sino también identificar qué señales en diferentes bandas de frecuencia y características proporcionan más información sobre dichos estados. Con estos datos principales, se implementaron modelos computacionales para medir la relación cerebro-corazón en diferentes etapas de la anestesia. Posteriormente, se clasificaron los diferentes estados de la anestesia considerando la teoría de información mutua e interdependencia no lineal. Este estudio abarca un mayor número de pacientes en comparación con investigaciones previas, incluyendo una diversidad de diagnósticos, edades y anestésicos.

Otra contribución fue la publicación en un evento internacional: *Analysis of electrocardiographic signals to assess heart rate variability under surgical context: a methodological proposal*

Muñoz-Ruiz, S.; Saavedra-Ordoñez, J.; Valencia-Fajardo, N.; Spicher, N.; Vargas- Cañas, R. & Idrobo-Ávila, E. (2024) Workshop Biosignals, Göttingen. DOI:

<https://doi.org/10.47952/gro-publ-215>, publicado en: <https://publications.goettingen-research-online.de/cris/events/events21061>

Adicionalmente, se participó en la propuesta para obtener una beca de “Visitas de estudio para grupos de estudiantes extranjeros a Alemania 2024” (Study visits for groups of foreign students to Germany 2024), ofrecida por el servicio alemán de intercambio académico DAAD, (por sus siglas en alemán: Deutscher Akademischer Austauschdienst). Esta beca fue aprobada y se tuvo la oportunidad de realizar una presentación de esta investigación en las universidades de Augsburg y Gotinga, en Alemania.

Se sometió del artículo titulado: ***“Tachogram processing considering different types of artifacts in heart rate variability analysis”*** en la revista *Royal Society Open Science* la cual esta indexada a *Scopus*.

1.7 Estructura del documento

En esta sección se presenta un resumen de los capítulos que componen este documento:

Capítulo 1. Introducción: se presenta un resumen general de la investigación realizada y se compone de siete partes: planteamiento del problema, pregunta de investigación, hipótesis, objetivos, metodología implementada, contribuciones, y descripción general del documento.

Capítulo 2. Marco teórico: se describen los conceptos más relevantes para esta investigación y se divide en dos partes: marco conceptual y marco teórico. El marco conceptual abarca temas como la anestesia, señales fisiológicas, la relación cerebro-corazón e inteligencia artificial. En el marco teórico, se presenta un resumen de los diferentes artículos de referencia utilizados en esta investigación.

Capítulo 3. Metodología: se explica el procedimiento realizado en cada una de las etapas propuestas en la CRISP-DM (desde la etapa dos hasta la cinco), para llevar a cabo esta investigación.

Capítulo 4. Resultados y análisis: se presentan los hallazgos obtenidos del procedimiento propuesto. Se exponen los resultados de la clasificación y otras técnicas implementadas, se analiza la relación cerebro-corazón y se discuten los resultados obtenidos.

Capítulo 5. Conclusiones y trabajo futuro: se exponen las conclusiones de esta investigación y se describen algunos trabajos futuros.

CAPÍTULO 2

2 MARCO TEÓRICO

En este capítulo se expone los principales temas y referencias bibliográficas que se estudiaron, las cuales se dividieron en tres partes: marco conceptual, marco referencial y análisis de la literatura. En el marco conceptual, se encuentran cuatro temas principales; el primero es acerca de la anestesia, donde se expone su significado y lo que sucede durante este estado. Luego, se presenta algunos datos importantes acerca de las señales fisiológicas de interés, que permiten conocer acerca de la relación cerebro – corazón y por último, se explica el concepto de inteligencia artificial. Por otra parte, en el marco referencial se exponen los artículos que sirvieron como guía para esta investigación y, finalmente, se expone un resumen de estos artículos en una tabla comparativa.

2.1 Marco Conceptual

2.1.1 Anestesia

La anestesia es un estado en el cual, el proceso de nocicepción necesario para prevenir respuestas del cuerpo, cambios neuroendocrinos y respuestas metabólicas al estrés, se inhiben a través de anestésicos, para realizar un determinado procedimiento quirúrgico [8]. Aunque existen tres tipos de anestesia (regional, local y general), la anestesia general es una de las más utilizadas. Durante la anestesia general, se observan comportamientos específicos como: la inconciencia, amnesia (pérdida de memoria), analgesia (perdida de percepción del dolor) y estabilidad de los sistemas autónomo, cardiovascular, respiratorio y termorregulador [14].

Los anestésicos pueden ser administrados por vía intravenosa, como el caso de Propofol, Dexmedetomidina y Ketamina, o por medio de la inhalación, como el Sevoflurano, Isoflurano, Desflurano y Óxido nitroso. Los anestésicos más utilizados son el Propofol y Sevoflurano [15]. En el cerebro se encuentran unos receptores ácido γ -aminobutírico del subtipo conocidos como A (GABAA), encargados del control de los iones de cloro (Cl-) entre las neuronas. Cuando el anestésico viaja por el torrente sanguíneo, como en el caso del Propofol, y llega a estos receptores, el anestésico se adhiere y el flujo de los iones de cloro se detiene, y es más difícil la conexión entre las neuronas (Figura 2) [16].




Figura 4. Comunicación entre el tálamo y la corteza [16].

Para cuantificar el nivel de consciencia de un paciente durante la anestesia se utiliza el **índice bispectral** (BIS, por sus siglas en inglés: Bispectral Index). Este parámetro se obtiene a través análisis avanzado del electroencefalograma (EEG), que implica la evaluación de la relación entre diferentes componentes de frecuencia. Los valores del BIS varía entre 0 y 100, donde valores cercanos a 0 indican una profunda sedación o incluso coma, mientras que valores cercanos a 100 indican un estado de vigilia y alerta (Figura 5) [17].

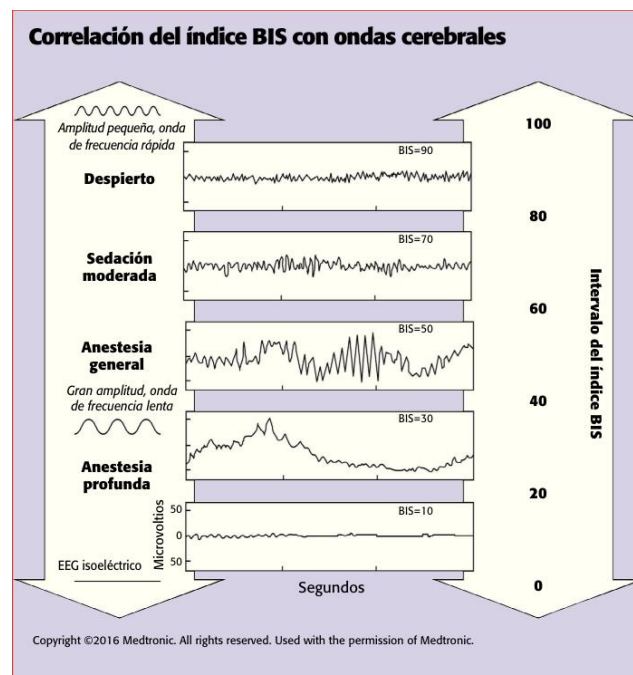


Figura 5. Uso de monitorización del índice bispectral para medir la profundidad de la sedación/analgesia [17].

2.1.2 Señales fisiológicas

El cuerpo humano se compone de diez sistemas: sistema respiratorio, sistema digestivo, sistema endocrino, sistema muscular, sistema esquelético, sistema inmunológico, sistema urinario, sistema reproductor, sistema nervioso y sistema circulatorio. Todos estos sistemas trabajan de manera conjunta para mantener el funcionamiento y homeostasis del organismo, y pueden ser observados o monitoreados mediante diferentes instrumentos. En el caso del sistema nervioso, la actividad cerebral, puede ser analizada a través del electroencefalograma y la actividad del corazón del sistema cardiovascular, mediante el electrocardiograma [18].

2.1.2.1 Sistema nervioso: el electroencefalograma

El sistema nervioso (SN), transmite señales entre el cerebro y el resto del cuerpo y se divide en dos partes principales sistema nervioso central (SNC), que está compuesto por la medula espinal y el encéfalo y sistema nervioso periférico (SNP) constituido por todos los nervios que ramifican desde la medula espinal. A su vez, el SNP está constituido por el sistema nervioso autónomo (SNA) y sistema nervioso somático (SNS) [18].

El encéfalo se constituye por tres partes: el tallo cerebral, el cerebelo y el cerebro. El cerebro es considerado como uno de los órganos más importantes, encargado de controlar diversas funciones del cuerpo humano, transmitiendo y recibiendo señales eléctricas y químicas hacia y desde los demás órganos a través del SN. En consecuencia, el SN y el cerebro deben estar funcionando de manera eficiente ante cambios y circunstancias diferentes, lo que significa que la actividad neuronal debe ser estable y coordinada [19].

El SNA es el encargado de regular las respuestas a diversos estímulos que modifican la homeostasis y ejerce un control estricto sobre las funciones esenciales tales como circulación, respiración, termorregulación y secreción hormonal [20]. A su vez el SNA, se divide en dos sistemas [20]: sistema nervioso simpático (SNS), que se encarga de aumentar la actividad de los diferentes órganos, como por ejemplo, aumentar la actividad cardíaca durante el ejercicio, y el sistema nervioso parasimpático (SNP), que al contrario del SNS, se encarga de disminuir las funciones alteradas para volver al equilibrio. El conocimiento del sistema nervioso autónomo durante la anestesia es crucial para asegurar la estabilidad hemodinámica, una adecuada función respiratoria y otros aspectos fisiológicos del paciente. Esto permite brindar una atención anestésica segura y optimizar los resultados quirúrgicos[20].

El electroencefalograma (EEG) es un registro, que permite medir continuamente la actividad producida por los potenciales eléctricos en la corteza cerebral [16]. Generalmente estas medidas se obtienen a través de electrodos que se sitúan en diferentes partes del cuero cabelludo y se pueden observar los ritmos u ondas alfa (9–12 Hz), beta (13–25 Hz), theta (5–8 Hz), delta (1-4 Hz) y gamma (26–80 Hz) (Figura 6) [16]. Cada uno de estos ritmos comprende rangos de frecuencia diferentes y están asociados a diferentes estados como sueño, calma, actividad mental. Durante la anestesia general, los

patrones de EEG se caracterizan por un aumento progresivo en la actividad de baja frecuencia y amplitud a medida que el nivel de anestesia general incrementa [16].




Figura 6. Diferentes tipos de ondas cerebrales [21].

2.1.2.2 Sistema Cardiovascular: el electrocardiograma

El sistema cardiovascular (SC), está formado por el corazón y los vasos sanguíneos (arterias, venas y capilares) [22]. El corazón, que en términos generales es el responsable de bombear sangre a todo el cuerpo, posee una red neuronal compleja compuesta de dos partes: sistema nervioso cardiaco extrínseco (SNCE) y sistema nervioso cardiaco intrínseco (SNCI). En el corazón, se encuentran 14000 neuronas y 550 ganglios aproximadamente [23]. Por este motivo, se ha considerado como “un cerebro en el corazón o pequeño cerebro” [22]. Lo anterior, ha permitido comprender que el “pequeño cerebro” le permite al corazón actuar independientemente del sistema nervioso central. Al mismo tiempo, detecta señales, las convierte en impulsos neurológicos y las procesa para luego enviar información al cerebro a través de las vías aferentes en los nervios vagos y en la columna vertebral [22].

El electrocardiograma (ECG) es una de las herramientas de diagnóstico más importantes para diversas enfermedades cardíacas, ya que permite observar a actividad eléctrica del corazón. Para esto, se colocan electrodos en la superficie del cuerpo y generalmente se utiliza un sistema estándar en el que se obtienen 12 derivaciones (Figura 7), para obtener una visión general de la actividad del corazón desde diferentes planos. Las derivaciones I, II, III, aVF, aVL y aVR se obtienen de tres electrodos, que se colocan en

el brazo derecho, brazo izquierdo y la pierna izquierda. Las derivaciones (V1, V2, V3, V4, V5 y V6) se extraen de los electrodos en el tórax [24].




Figura 7. Ritmo normal del corazón [24].

- **Variabilidad de la frecuencia cardiaca**

El electrocardiograma se caracteriza por una secuencia recurrente de ondas P, QRS, T y una onda U condicional, que representa la despolarización rítmica y la repolarización del miocardio asociada a las contracciones de las aurículas y los ventrículos en cada ciclo cardíaco. Los intervalos RR del electrocardiograma (Figura 8), representan la distancia entre los picos R del complejo QRS, que en términos generales representa la despolarización de los ventrículos [24]. Estos intervalos RR pueden ser representados gráficamente en un tacograma (TCG), donde el eje horizontal representa el tiempo o el número de latidos sucesivos y el eje vertical muestra la duración de los intervalos RR en milisegundos. El tacograma es una herramienta útil para visualizar y analizar [24].




Figura 8. Descripción de los diferentes tipos de ondas en un electrocardiograma [24].

Los intervalos RR permiten determinar la variabilidad de la frecuencia cardíaca (VFC), que es la variación del lapso entre latidos cardíacos consecutivos a lo largo del tiempo. La VFC, resulta de la actividad descendente y ascendente que se producen en las dos ramas del SNA (simpática y parasimpática). En términos de frecuencia, la VFC se divide en tres bandas principales [1]:

- Frecuencias altas (0.15 - 0.4 Hz): reflejan la actividad parasimpática y se le suele denominar banda respiratoria, porque corresponde a las variaciones de frecuencia cardíaca relacionadas con el ciclo respiratorio.
- Frecuencias bajas (0.04 – 0.15 Hz): refleja la actividad barorreceptora. Los barorreceptores son mecanorreceptores que contribuyen al control de la frecuencia cardíaca.
- Frecuencias de muy baja frecuencia (0.033 – 0.04 Hz): estas frecuencias están asociadas con la muerte por arritmia y el trastorno por estrés.

2.1.3 Relación cerebro - corazón

Se ha evidenciado que el corazón posee un sistema de comunicación mucho más extenso con el cerebro que otros órganos [1]. Esta comunicación se realiza principalmente de cuatro maneras: neurológicamente (a través de impulsos nerviosos, a través de la rama parasimpática y simpática del SNA [1]), bioquímicamente (a través de hormonas y neurotransmisores), biofísicamente (a través de las ondas de presión) y energéticamente (a través de las interacciones de los campos magnéticos).

Las vías eferentes (descendentes) del SNA están involucradas en regular el corazón, sin embargo, la mayoría de las fibras de los nervios vagos son de naturaleza aferentes (ascendentes). Básicamente, el nervio vago (parasimpático) está formado

principalmente por fibras aferentes (que fluyen al cerebro) que se conectan a la médula. Los nervios aferentes simpáticos se conectan primero con los ganglios cardíacos extrínsecos, luego con el ganglio de la raíz dorsal y la médula espinal. Una vez que las señales aferentes llegan a la médula, viajan a las áreas subcorticales (tálamo, amígdala) y luego a las áreas corticales superiores, lo que implica que el corazón envía más información al cerebro que la que este envía al corazón (Figura 9) [1].




Figura 9. Las vías de comunicación neurales que interactúan entre el corazón y el cerebro [25].

Estos hallazgos, les ha permitido a diferentes investigadores evaluar cómo es la relación entre el cerebro y corazón, a través de algoritmos, técnicas o ecuaciones matemáticas. Estos se han implementado durante estados y comportamientos distintos, como por ejemplo, la meditación, estrés y concentración. En particular, la coherencia de las ondas cerebrales ha sido evaluada a través de la siguiente ecuación [26]:

$$\Gamma^2 = \frac{G_{xy}(f)^2}{G_{xx}(f)G_{yy}(f)} \quad (1)$$

Donde $G_{xy}(f)$ es la densidad espectral de potencia cruzada y $G_{xx}(f)$ y $G_{yy}(f)$ son densidades espectrales de potencia automática para cada canal X e Y, respectivamente.

Por otra parte, la coherencia cardíaca se ha formulado de la siguiente manera [26]:

$$\text{CoherenciaCardiaca} = \frac{\text{PotenciaMaxima}}{\text{PotenciaTotal}} \quad (2)$$

donde la potencia máxima se determina calculando la integral en una ventana de 0,03 Hz de ancho, centrada en el pico más alto en el rango de 0,04-0,4 Hz del espectro de potencia VFC, y la potencia total se determina calculando la integral en una ventana de 0,0033-0,4 Hz de ancho. La coherencia cardíaca tiene un valor entre 0 y 1 e indica la magnitud de similitud entre la forma de onda del tacograma y una onda sinusoidal [26].

2.1.4 Inteligencia artificial

La inteligencia artificial (IA) es una rama de la ciencia informática que se enfoca en imitar rasgos cognitivos asociados a la inteligencia humana, como el aprendizaje, la resolución de problemas y el reconocimiento de patrones, a través de sistemas informáticos, técnicas matemáticas, y combinaciones de algoritmos. De la inteligencia artificial, se derivan ramas especializadas en diferentes campos, tales como: el aprendizaje automático o de máquina (ML) y aprendizaje profundo (DL) (Figura 10) [27].

El aprendizaje automático es una rama que se enfoca en el desarrollo de algoritmos y técnicas, para que las máquinas aprendan de datos registrados, con la finalidad de hacer predicciones a partir de estos, optimizar una función de utilidad y rendimiento en una tarea específica con el tiempo, extraer estructuras ocultas de los datos y/o clasificar los datos. Dentro del aprendizaje automático se encuentra el aprendizaje profundo (Deep Learning) (Figura 10), que utiliza redes neuronales profundas para modelar y resolver problemas complejos y son utilizadas en aplicaciones como reconocimiento de voz, reconocimiento de imágenes y juegos [27].

La inteligencia artificial junto con el aprendizaje automático han ayudado al análisis automatizado y eficaz de datos médicos, ya que las redes neuronales son una de las técnicas utilizadas para resolver una amplia gama de tareas médicas, como la agrupación, la detección y el reconocimiento de enfermedades [12].




Figura 10. Subcampos de la IA.

2.2 Marco Referencial

2.2.1 Referencias sobre análisis de coherencia

Técnicas de procesamiento de señales para el análisis de coherencia entre señales de ECG y EEG con un estudio de caso [28]

En este trabajo, se discuten diferentes técnicas estudiadas en artículos anteriores para comprender y analizar el sistema nervioso central a través de las señales EEG y ECG, y su correlación. Estas señales, pueden ser útiles para el estudio de problemas relacionados con el corazón y cerebro. Para su estudio, destacan algunos análisis de coherencia, técnicas matemáticas, técnicas experimentales y el procesamiento de las señales biomédicas, que permiten determinar la correlación entre las señales. En esta investigación, los autores implementan la coherencia de magnitud al cuadrado (MSC) y la coherencia de fase (PS) para determinar el análisis de asociación funcional entre las señales ECG y EEG obtenidas de diferentes regiones del cerebro: (Fp1-Fp2), (C3-C4), (P3-P4), (O1-O2). Para este estudio, contaron con cinco personas sanas de 18 a 35 años. Para análisis de MSC, utilizaron la transformada de Fourier de la función de autocorrelación (ACF) de una señal x , transformada de Fourier de la ACF de una señal y y transformada de Fourier de la función de correlación cruzada (CCF). Además, utilizaron el método de densidad espectral de potencia cruzada (CPSD), para la obtención de los parámetros estadísticos, principalmente amplitudes máximas, mínimas, y media de las señales adquiridas. Finalmente, los valores máximos MSC se obtienen para frecuencias de 0,1 Hz entre ECG y EEG de todas las regiones del cerebro, mientras que, para el análisis de coherencia de fase, los valores máximos entre las dos señales se obtuvieron, específicamente en la parte frontal 0,09108 y occipital 0,08314.

Coherencia temporal entre la variabilidad de la frecuencia cardíaca y la actividad del EEG en pacientes epilépticos: un análisis de acoplamiento avanzado entre redes fisiológicas [11]

En esta investigación, evaluaron la coherencia temporal entre VFC y la actividad del EEG con 20 canales, en 18 niños con epilepsia temporal lateralizada (TLE). Para ello, utilizaron la descomposición en modo empírico multivariado (MEMD) para encontrar las funciones de modo intrínseco (FMI), transformada de Hilbert, transformada Wavelet de Morlet continua (CMWT), y se aplicaron técnicas de descomposición tensorial de los mapas de coherencia tiempo-frecuencia para explorar las características topográficas-tiempo-frecuencia del análisis de coherencia. Luego de extraer las envolventes de EEG y la VFC, se estimó la coherencia mediante el análisis de coherencia variante en el tiempo (tvCOH). En los resultados se observa que, las envolventes del EEG estaban fuertemente correlacionadas con la oscilación de baja frecuencia de la VFC ($LF \approx 0,1$ Hz) antes y después de la convulsión.

Interacción entre las señales de EEG y ECG durante y después de eventos de apnea obstructiva del sueño con o sin excitaciones [9]

En este estudio, informan sobre la interacción entre las señales EEG y ECG de diez pacientes con apnea obstructiva del sueño (OSA) de 54 ± 9 años y cinco pacientes sanos de 51 ± 8 años. En esta investigación se centraron en medir la densidad espectral de potencia cruzada de las señales ECG y EEG, utilizando el método de periodograma modificado promedio de Welch, para luego calcular la coherencia entre dos señales (ECG-EEG) en diferentes bandas de frecuencia ($\sim 0-40\text{Hz}$) en eventos respiratorios. Los resultados más promisorios se observan en pacientes con OSA en los estados de sueño arousal y NREM con una coherencia de $0,62 \pm 0,12$, dentro del rango de frecuencias de 16 - 25 Hz y también se observa una correlación alta en el rango de frecuencias (12-16 Hz) con una correlación $0,67 \pm 0,15$, pero solamente en el estado REM. En general, se encontró que la coherencia es mayor en eventos de respiración normal en el sueño REM que en el sueño NREM. Adicionalmente, se evidenció diferencias significativas en la coherencia entre los eventos de apnea obstructiva del sueño con y sin arousal en diferentes bandas de frecuencia en el sueño NREM y REM. Por lo que se concluye, que la coherencia cambia dependiendo de las diferentes etapas del sueño y varía dependiendo de los eventos de apnea obstructiva del sueño con y sin arousal.

2.2.2 Referencias sobre análisis de correlación

Correlaciones entre la complejidad de la señal de la actividad eléctrica cerebral y cardíaca: un análisis de entropía multiescala [29]

En esta investigación, los autores midieron la complejidad de la señal del electroencefalograma (EEG) y la VFC de 87 pacientes geriátricos con corazones sanos y capacidades cognitivas variadas. En este caso implementaron el análisis de entropía multiescala (MSE) a las señales EEG en el rango de frecuencia de 1-58 Hz en tres diferentes estados (vigilia, estimulación fónica de frecuencias rápidas (PS rápido) y estimulación fónica de frecuencias lentas (PS lento)) y tres series de tiempo de intervalo RR (RRI) (estado despierto, sueño y durante el mismo periodo de tiempo del EEG) para cada paciente. Para analizar la correlación entre estas variables se utilizó la correlación parcial de Pearson que permitió observar que la relación LF/HF de la VFC está positivamente correlacionada con los valores de MSE de escalas de tiempo grande (escalas 6-20) de la señal EEG y negativamente correlacionada con los valores de MSE de estado de reposo-despierto en las escalas de tiempo más finas (escalas 1-5) de la señal EEG.

Un índice bimodal robusto que refleja la dinámica relativa de EEG y HRV con aplicación en el monitoreo de la profundidad de la anestesia [4]

En este estudio, los autores se enfocan en la integración de datos de EEG y VFC para mejorar la evaluación de la función cerebral mediante el desarrollo de un marcador único

llamado "cociente de cumulantes", que cuantifica la desviación de la dinámica de EEG de la autosimilitud en comparación con la dinámica de VFC. Los datos experimentales se obtuvieron de 20 pacientes con cerebros sanos que se sometieron a una operación y fueron anestesiados con Propofol. Se encontró que la relación de EEG a VFC de los cumulantes se acerca sistemáticamente a cero con un aumento en la profundidad de la anestesia. En resumen, el estudio muestra cómo la combinación de datos de EEG y VFC puede ser útil para evaluar la función cerebral y cómo el marcador de cociente de cumulantes puede ser utilizado para cuantificar la desviación de la dinámica de EEG de la auto-similitud en comparación con la dinámica de VFC.

Correlación cruzada de las bandas de frecuencia del EEG y variabilidad de la frecuencia cardíaca para la clasificación de la apnea del sueño [10]

En este estudio, los autores evalúan la correlación cruzada de las bandas de frecuencia del EEG en diferentes bandas de frecuencia (delta, theta, alfa, sigma y beta) y la también en las bandas de frecuencia de la VFC (baja frecuencia (LF), alta frecuencia (HF) y la relación LF/HF) para la clasificación de la apnea del sueño. Para este estudio se recolectarán señales de EEG y ECG de ocho pacientes sanos (cinco hombres y tres mujeres) con edades de $48,13 \pm 10,52$ años y once pacientes con apnea del sueño (nueve hombres y dos mujeres) con edades de $50,64 \pm 11,39$ años. En esta investigación, además de enfocarse en análisis estadístico de las dos señales, se evaluó un modelado discriminativo gaussiano para la clasificación de apnea sana y del sueño. Para el análisis estadístico, se implementó la corrección de Bonferroni con un nivel de significancia de 0,008 y se calculó la prueba no paramétrica de Mann-Whitney con el fin de evaluar las diferencias significativas de los parámetros de banda de frecuencia de VFC y EEG. Los resultados muestran que, las bandas delta, sigma y beta del EEG muestran una fuerte correlación con las características de VFC en pacientes con apnea del sueño. Por ejemplo, se muestra una correlación de 0,29* de las bandas de frecuencia delta y (LF/HF) en pacientes con apnea en la etapa S3 del sueño, y en pacientes sanos en ese mismo rango de frecuencias se observa una correlación de -0,88** pero en la etapa S4. Así mismo, se observa una correlación de 0,28 en pacientes sanos, pero en las bandas de frecuencia sigma y (LF/HF) en la misma etapa. También se observan altas correlaciones de pacientes sanos y con apnea entre las bandas delta y HF de 0,74* y Apnea y theta 0,47* respectivamente en distintas etapas del sueño (* Nivel alfa en $P < 0,05$, ** corrección de la velocidad alfa en $P < 0,001$).

Correlación entre la electroencefalografía y la variabilidad de la frecuencia cardíaca durante el sueño [30]

En este artículo, los autores investigan la posible correlación entre la actividad del sistema nervioso autónomo y los patrones de ondas cerebrales durante el sueño ya que puede ser útil para observar la calidad del sueño y la salud del paciente. Para ello, se analizaron registros de EEG y ECG de siete hombres sanos ($24 \pm 0,7$ años) durante una noche de sueño. Para encontrar la correlación entre las señales, estimaron las diferentes bandas de

frecuencia delta, sigma y beta del EEG a través de la transformada rápida de Fourier, y en cuanto a la señal ECG se calcularon los índices (LF, HF y LF/HF) de VFC. Los resultados muestran una correlación significativa ($r=-0,44$, $P<0,001$) entre la potencia de las ondas delta del EEG y los espectros de potencia bajos (LF) y una correlación ($r=-0,41$, $P<0,001$) entre la relación de las frecuencias bajas y altas (LF/HF) de VFC. Los autores sugieren que la anterior correlación puede reflejar la actividad del sistema nervioso parasimpático, que es responsable de la relajación y la recuperación del cuerpo durante el sueño.

2.2.3 Referencias sobre análisis de interacción

Interacción del cerebro y el corazón durante el sueño en la apnea sana y del sueño [31]

En esta investigación se explora la interacción entre el cerebro y el corazón durante el sueño en individuos sanos y con apnea del sueño durante diferentes etapas. Para ello, se plantea un análisis multivariado de la actividad de EEG de los canales (C4-A1, C3-A2, O2-A1) y la derivación II de ECG. El estudio se enfoca principalmente en tres medidas, método lineal (correlación cruzada), teoría de la información (información mutua) e interdependencia no lineal. Estas técnicas son aplicadas a las señales de once pacientes (nueve hombres y dos mujeres) con síndrome de apnea-hipopnea y edad $50,64 \pm 11,39$ y a ocho pacientes sanos de edad $48,13 \pm 10,52$. Los resultados principales para cada medida son los siguientes: para la correlación cruzada se obtuvo que en el estado REM en pacientes saludables la correlación es negativa y menor a $-0,2$ para los canales C3-A2, O2-A1 y positiva para el canal C4-A1, y el estado Sueño ligero (LS) y REM de personas con apnea las correlaciones fueron positivas y cercanas a $0,1$ para los canales C3-A2, O2-A1 y negativa para el canal C4-A1. La información mutua reveló un aumento de la transmisión de información entre el corazón y el cerebro durante el estado de sueño profundo, en ambos grupos, particularmente en el área central del cerebro. Sin embargo, en todas las etapas del sueño para la apnea del sueño fue más bajo que el saludable. En cuanto la interdependencia no lineal los resultados sugieren que el cerebro depende más de la actividad eléctrica del corazón durante el sueño en personas con apnea del sueño, lo que implica que, al aumentar de actividad simpática del ANS, la interacción cerebro-corazón no lineal se altera como lo han demostrado otros estudios.

Sincronización de fase y acoplamiento direccional entre el cerebro y el corazón durante el sueño [32]

Este trabajo se enfoca en estudiar la sincronización de fase y el acoplamiento direccional mediante el índice de sincronización (SI) y el índice de direccionalidad (ID), entre las señales del corazón (ECG) y las bandas de frecuencia de EEG delta1 (0,5-2Hz), delta2 (2-4Hz), theta (4-8Hz), alpha1 (8-10Hz), alpha2 (10-12Hz), sigma (12-14Hz), beta (14-30Hz), gamma (30-45Hz) durante diferentes etapas del sueño. Para este estudio se analizaron datos de once pacientes (nueve hombres y dos mujeres) con un índice promedio de apnea-hipopnea y ocho pacientes sanos (cinco hombres y tres mujeres). Para

el cálculo de los índices SI e ID se utilizaron las fases instantáneas y verdaderas de las señales EEG y ECG. La fase instantánea de la señal EEG se estimó mediante la transformada de Hilbert (HT), mientras que la fase instantánea de la señal ECG se calculó mediante el método de eventos de marcador. La fase verdadera se obtuvo a partir de la fase instantánea mediante un método implementado a partir de un estudio anterior. Los resultados muestran que el SI entre en la mayoría de las bandas de frecuencia de EEG, excepto delta1 y delta2 y la señal ECG para el grupo de apnea fueron más altas que el grupo sano, sin embargo, en esas bandas delta se encontró una fuerte sincronización de fase. También se observó un fuerte acoplamiento unidireccional del cerebro al corazón en todas las etapas del sueño, lo que sugiere que el cerebro tiene un papel importante en la regulación de la actividad cardíaca durante el sueño.

Análisis de la pérdida y recuperación de la conciencia: patrones de conectividad funcional y cambios en la variabilidad de la frecuencia cardíaca durante la anestesia inducida por Propofol [3]

Esta investigación se enfoca en analizar los patrones de conectividad funcional y la VFC durante las diferentes etapas de la anestesia. Los autores realizaron un estudio en el que midieron la actividad cerebral y la VFC de once pacientes sometidos a anestesia con Propofol. Para este estudio se realizó un análisis paralelo de las señales EEG y VFC, en el que se implementó la coherencia parcial dirigida (PDC), para estudiar el patrón de conectividad de las señales EEG. También se calculó la potencia relativa (RP) en las diferentes bandas de frecuencia y entropía condicional corregida (CCE), para evaluar la complejidad autonómica cardíaca. Para establecer los efectos de las condiciones, se implementó un análisis de varianza de medidas repetidas (RM-ANOVA). Los resultados mostraron que la conectividad funcional disminuyó significativamente durante la pérdida de conciencia y se recuperó gradualmente durante la recuperación de la conciencia. Además, la variabilidad de la frecuencia cardíaca disminuyó durante la pérdida de conciencia y se recuperó durante el restablecimiento de la conciencia. Los autores concluyen que estos hallazgos pueden tener implicaciones importantes para la práctica clínica de la anestesia, ya que sugieren que la monitorización de la conectividad funcional y la VFC pueden ser útiles para evaluar el estado de conciencia de los pacientes durante la anestesia. Además, estos hallazgos pueden tener implicaciones más amplias para la comprensión de la conciencia y la conectividad cerebral en general.

2.3 Análisis de la literatura

Tabla comparativa

Después de una revisión bibliográfica, se presenta un resumen de las investigaciones más relevantes en este campo de investigación (tabla1). Se proporciona el objetivo, el conjunto

de datos, los canales y/o anestésicos y los diferentes enfoques utilizados y resultados por cada uno de estos.

Tabla 1. Resumen de las investigaciones realizadas sobre la relación entre el cerebro y corazón.

Ref	Objetivo	Canales/Anestésicos	Conjunto de datos	Enfoque	Resultados
[28]	Investigar el análisis de la asociación funcional entre el ECG y el EEG.	EEG - (Frontal, parietal, occipital, central)	5 personas sanas	Magnitud coherencia cuadrada (MSC) Y Coherencia de fase (PC)	Los máximos valores de MSC se encuentran cerca de la frecuencia 0.1 Hz.
[11]	Investigar la coherencia temporal entre VFC y EEG y cómo varía en diferentes momentos del ciclo de la convulsión.	EEG -20 canales	18 pacientes con epilepsia temporal lateralizada (TLE)	Análisis de coherencia variante en el tiempo (tvCOH)	Correlación entre la actividad delta del EEG y espectro de baja frecuencia (LF) de HRV, en los períodos preictal y postictal.
[9]	Calcular la coherencia entre las señales ECG y EEG en diferentes bandas de frecuencia en eventos respiratorios.	No especifica	10 pacientes con apnea obstructiva del sueño (OSA) y 5 pacientes sanos.	Coherencia Espectro de potencia con método de Welch	La coherencia cambia dependiendo de las diferentes etapas del sueño.
[29]	Examinar la asociación inversa entre los valores de entropía multiescala (MSE) de la frecuencia cardíaca en reposo y la actividad cerebral medida por el EEG.	No especifica	87 pacientes geriátricos	Análisis de entropía multiescala (MSE) y Correlación parcial de Pearson	Correlaciones significativas entre la complejidad de las señales cerebrales y cardíacas en varias áreas.
[4]	Determinar cómo se desvía la autosimilitud de EEG con respecto a la VFC	EEG - 10 canales y Propofol	20 pacientes en cirugía	Cociente de cumulantes	La autosimilitud de las señales tiende a 0 a medida que aumenta la profundidad de la anestesia.
[10]	Evaluar de la correlación cruzada entre las bandas de frecuencia de EEG y VFC en pacientes clínicos con apnea normal y del sueño.	No especifica	8 pacientes sanos y 11 pacientes con apnea del sueño	Correlación cruzada	Se observaron correlaciones altas (negativas y positivas) con el espectro de alta y baja frecuencia de VFC y las ondas delta y alfa en pacientes sanos durante algunas etapas del sueño.
[30]	Determinar la posible correlación entre EEG y las actividades nerviosas autónomas.	No especifica	7 personas sanas	Coeficiente de correlación de Pearson	Se detectó que en el ciclo del sueño la correlación es negativa entre potencia delta, LF y LF/HF.
[31]	Evaluar el análisis multivariado de la actividad de EEG y ECG en los pacientes sanos y apnea del sueño durante el sueño diferentes etapas.	EEG - (3 canales) y ECGII	11 pacientes con índice de apnea-hipopnea (IAH)	Método lineal (correlación cruzada), Teoría de la información (información mutua) e Interdependencia no lineal	Se detectaron correlaciones positivas y negativas bajas entre las señales EEG y ECG. Además, se observa una dependencia mayor del corazón al cerebro que la del cerebro corazón.

[32]	Investigar cómo interactúan la fase de la frecuencia cardíaca del ECG y las diferentes bandas de frecuencia del EEG durante las diferentes etapas del sueño en la apnea sana y del sueño.	No especifica	11 pacientes con un índice promedio de apnea-hipopnea y 8 pacientes sanos	Medidas de sincronización de fase: índice de sincronización (SI) y índice de direccionalidad (d)	Se demostraron correlaciones positivas con las ondas delta en diferentes etapas. El índice d mostró la tendencia hacia una interacción unidireccional dominante (del cerebro al corazón) a medida que aumenta la frecuencia del EEG.
[3]	Analizar las características del SNC y el ANS a través del análisis de EEG y VFC	EEG -19 canales /Propofol y Remifentanilo	Muestra de 11 pacientes sometidos a cirugía de columna	Coherencia Parcial Dirigida (PDC), potencia relativa (RP), Entropía condicional corregida (CCE)	Observaron que la conectividad funcional entre EEG y VFC, disminuyó significativamente durante la pérdida de conciencia y se recuperó gradualmente durante la recuperación de la conciencia.

Algunos investigadores han correlacionado las señales provenientes del cerebro y del corazón (EEG, ECG y VFC). Estas correlaciones se han efectuado principalmente de dos maneras: descomponiendo la señal EEG en diferentes bandas de frecuencia y correlacionando con la señal ECG o con VFC, o en algunos casos, los autores han intentado correlacionar las señales sin descomponer ninguna de las dos señales. Para la descomposición de las señales, han optado por implementar espectros de potencia basados en el método de Welch o de Fourier. Además de implementar técnicas de correlación, los autores han empleado métodos que permiten observar la tendencia de los órganos y cómo estos se asocian o sincronizan, proporcionando información sobre la relación cerebro-corazón. Sin embargo, los resultados de las investigaciones no permiten establecer una clara conexión entre el cerebro y el corazón o como esta se puede evaluar. No obstante, algunas brechas de investigación en estos estudios están relacionadas con:

- El número de pacientes que se emplearon para las investigaciones en la mayoría de los casos no sobrepasa de 20. Además, los datos solo se recopilaron de participantes con una composición de género desequilibrada.
- Para el caso de los artículos [4] y [3] no se demostraron con otros fármacos y ni con diferentes tipos de cirugía.
- La edad es un factor significativo y es una limitación en las investigaciones.
- En la mayoría de los trabajos no se tienen en cuenta métricas que permitan observar el desempeño de los enfoques.
- En la mayoría de los artículos tratan técnicas estadísticas y se encontraron solamente técnicas de aprendizaje automático durante análisis del sueño.

CAPÍTULO 3

3 METODOLOGÍA

En este capítulo se describen las fases para llevar a cabo el análisis de la relación cerebro-corazón. De acuerdo con la metodología CRISP-DM, este proceso incluye la comprensión inicial de la base de datos, preparación de los datos, modelado y evaluación.

3.1 Comprensión de los datos

En esta fase, se pretende analizar los datos disponibles en la base de datos. Esto implica a su vez diferentes etapas: recolección, descripción, exploración y verificación de los datos.

3.1.1 Recolección de los datos

Los datos utilizados en esta investigación se descargaron de Vitaldb [12], que es una base de datos gratuita, creada en el hospital de la Universidad Nacional de Seúl en Corea. Los datos fueron capturados con un software de alta resolución (Vital Recorder) y luego se almacenaron en una nube pública [12].

Esta base de datos contiene información de pacientes que se sometieron a cirugía no cardíaca. Los datos están organizados en archivos csv separados en tres conjuntos de datos. Para acceder a ellos, se debe ingresar a <https://vitaldb.net/dataset/?query=lib>. En este enlace, se encuentran cuatro pestañas (figura 11). Cada una de estas, corresponde a:

- Descripción general: esta sección proporciona un resumen de los diferentes datos recopilados, que incluyen información clínica, los parámetros hemodinámicos y resultados de laboratorio.
- Interfaz de programación de aplicaciones web (API web): en esta pestaña, se detalla cómo acceder al conjunto de datos abiertos de VitalDB a través del protocolo seguro HTTPS, brindando una guía sobre cómo interactuar con la API web.
- Biblioteca de Python: en esta sección se presenta una explicación detallada y ejemplos prácticos de cómo utilizar la biblioteca VitalDB en Python, facilitando su integración y uso.
- Visor de datos: aquí se encuentra una interfaz que permite a los usuarios seleccionar y visualizar los datos deseados en línea, así como la descarga para su análisis.



Figura 11. Interfaz de la base de datos.

3.1.2 Descripción de los datos

En esta etapa, se observó cómo estaban distribuidos los datos. Para ello se ingresó a la pestaña API web (figura 11), y se identificaron tres grupos distintos de datos que pueden ser leídos como Dataframe, mediante la biblioteca de *Pandas* de Python utilizando la función *read_csv* con los siguientes enlaces:

- Para obtener la información clínica: <https://api.vitaldb.net/cases>.
- Para cargar los parámetros hemodinámicos: <https://api.vitaldb.net/trks>.
- Para cargar los resultados de laboratorio: <https://api.vitaldb.net/labs>.

Cada uno de estos DataFrame, contienen información específica de cada paciente. El primero, contiene información sobre datos demográficos, datos preoperatorios e intraoperatorios. El segundo conjunto de datos corresponde a los dispositivos que se utilizaron en cada paciente, como por ejemplo, los dispositivos para medir las señales de EEG y ECG. Por último, en el tercer grupo se encuentran los resultados de laboratorio, que incluye datos correspondientes al análisis de sangre de los pacientes.

3.1.3 Exploración de los datos

Para obtener una visión general de los datos a utilizar, se realizaron dos tipos de análisis durante esta fase. El primero, consistió en observar el comportamiento de las señales EEG (canal uno y dos) y ECG (derivación II) mediante gráficos de cajas (*box-plots*). Estos gráficos permitieron realizar un análisis comparativo de características extraídas de las señales en el dominio del tiempo, entropías y características caóticas (fractales). Para esto, se exploraron segmentos del inicio, intermedio y final de las señales de un grupo de diez pacientes que compartían el mismo tipo de anestesia, procedimiento quirúrgico y posición durante la intervención.

La segunda parte consistió en proporcionar una visión detallada de la distribución y variabilidad de los datos; esto para permitir una comprensión general de la distribución los datos contenidos principalmente en la información clínica y en los parámetros hemodinámicos. Para ello, se llevaron a cabo cálculos de estadísticas descriptivas, incluyendo la media, mediana, desviación estándar, mínimo y máximo de los diferentes parámetros.

3.1.4 Verificación de la calidad de los datos

En esta fase, se buscó determinar la integridad del conjunto de datos mediante la identificación de valores faltantes, así como la detección de valores atípicos. Para lograr este objetivo, se establecieron los siguientes procesos:

- Obtención de información del DataFrame: en este paso inicial, se recopiló información general del DataFrame, incluyendo los tipos de datos de cada columna y la estructura general de los mismos.
- Verificación de valores nulos: se identificó la presencia de valores nulos en cada DataFrame y se analizó si podían afectar en esta investigación de manera general y de qué manera se podrían tratar.
- Visualización de señales: se visualizaron diferentes segmentos de las señales, tanto de buena como mala calidad, para identificar los posibles ruidos.

3.2 Preparación de los datos

Durante esta etapa; se definieron los criterios para la selección del grupo de pacientes objeto de estudio. Posteriormente, se llevó a cabo el preprocesamiento de las señales, seguido de la extracción de características en diferentes dominios, y luego se obtuvo el DataFrame final para el análisis posterior.

3.2.1 Selección de los datos

Para garantizar la homogeneidad del grupo de pacientes, se implementaron los siguientes criterios (Tabla 2):

- Señales de interés EEG, ECG y BIS: se realizó un filtro para conocer cuántos pacientes tenían estas tres señales; esto dado que, no todos los pacientes tienen estas señales registradas. Cabe resaltar que, además de las señales de interés, se tuvo en cuenta la señal BIS, con el fin de realizar el análisis de la relación cerebro - corazón durante las diferentes etapas de la anestesia.
- Tipo de anestesia y cirugía: este filtro se restringe a la selección de pacientes que fueron sometidos únicamente a anestesia y cirugías generales.
- Posición decúbito supino y abordaje quirúrgico abierto: se seleccionó estos parámetros, debido a que cuentan con la mayor cantidad de datos en la base de datos (tabla 6).

- Datos demográficos: en esta parte se incluyeron pacientes con un índice de masa corporal (IMC) dentro un rango considerado como normal según los estándares médicos y dentro de un rango de edad determinado; para que las diferencias biológicas y fisiológicas entre personas de diferentes edades no influyan significativamente en los resultados.
- Morbilidad preoperatoria: se estableció como requisito que el grupo de pacientes presentara una función pulmonar y un ritmo cardíaco preoperatorio normal. Además, se excluyeron aquellos pacientes con hipertensión o diabetes. Por otro lado, se incluyeron pacientes con Estado Físico de la Sociedad Americana de Anestesiología (ASA, por sus siglas en inglés) de uno o dos, según lo establecido.

Tabla 2. Descripción general del grupo de pacientes a investigar.

Parámetros	Criterio
Señales incluidas	EEG, ECG y BIS
Sitio o tipo quirúrgico	Sin restricción
Diagnóstico	Sin restricción
Tipo de anestesia	General
Tipo de cirugía	General
Posición	Decúbito Supino
Abordaje quirúrgico	Abierto
Índice de masa corporal	Normal
ASA	Uno y dos
Hipertensión	0
Diabetes	0
Función pulmonar	Normal
Ritmo cardíaco	Normal

3.2.2 Preprocesamiento de las señales

En esta etapa, se detalla el conjunto de procedimientos aplicados para preparar y mejorar la calidad de las señales antes de su análisis.

3.2.2.1 Preprocesamiento de las señales EEG y ECG

El preprocesamiento de señales es crucial en el análisis de datos. Las señales, suelen contener artefactos derivados que incluyen: movimientos musculares, interferencias eléctricas externas, equipos de medición, entre otros [33]. Estos artefactos afectan el análisis de forma considerable y deben ser tratados para obtener resultados confiables. Con este fin, se implementaron tres pasos clave: primero, mediante el algoritmo presentado en [34], se seleccionaron segmentos de EEG y ECG de buena calidad, luego se implementó un filtro para eliminar el ruido de la red eléctrica y finalmente se realizó el suavizado de la señal.

- **Selección de segmentos de buena calidad:** para obtener segmentos de buena calidad, el algoritmo se fundamenta en que cuando una señal es corrupta, características tales como valores máximos y mínimos, desviación estándar, así como tasa de cruces por cero, presentan cambios abruptos [34]. Para la selección de segmentos de buena calidad, se deben establecer los siguientes parámetros: las señales a analizar (EEG y ECG), frecuencia de muestreo de cada señal (250 Hz), tiempo en segundos de las ventanas más pequeñas en las que la señal se dividiría en primer lugar para analizar la señal (5s), tiempo de ventana en segundos en el que se realiza el análisis posterior de las señales (60s) y además también se puede establecer si se hace un análisis con superposición de las ventanas o no mediante un operador booleano. En este caso se estableció como *False* (sin traslape o superposición).
- **Filtrado:** para eliminar las frecuencias indeseadas asociadas con el ruido de la red eléctrica y otros artefactos, se establecieron tres bandas de rechazo, con rangos de frecuencia entre 59.98-60.01 Hz, 89.98-90.01 Hz y 119-121 Hz. Estas bandas de filtrado y el tipo de filtro a implementar se definieron tras una serie de experimentos que permitieron identificar y eliminar las frecuencias no deseadas de manera precisa. Luego, se utilizó la función *scipy.signal.butter*, para crear filtros de Butterworth de tercer orden para cada banda de rechazo especificada y finalmente, se aplicó cada filtro de rechazo de banda a la señal original utilizando *scipy.signal.filtfilt*.
- **Suavizado de las señales:** se filtraron las señales utilizando la transformada wavelet ya que es útil para preservar las características importantes de la señal mientras se reduce el ruido. En esta investigación, se utilizó la transformada de Wavelet fue empleada con dos niveles de descomposición usando la onda madre biorthogonal 3.5 (Bior 3.5) [35].

3.2.2.2 Preprocesamiento de la señal BIS

En comparación con las señales EEG y ECG, la señal BIS requiere un preprocesamiento relativamente sencillo. Principalmente, se centra en dos pasos clave: tratamiento de datos faltantes y remuestreo o interpolación para igualar la longitud con las otras señales.

- **Tratamiento de datos faltantes:** para tratar los valores faltantes en la señal BIS, primero, se identificaron los valores que aparecían con valores NaN y se cambiaron por ceros. Luego, para garantizar una estimación precisa de los datos perdidos y mantener la coherencia del conjunto de datos, se implementó un modelo de regresión para predecir los valores faltantes basándose en los valores conocidos.
- **Remuestreo de los datos:** para asegurar que la señal BIS tenga el mismo tamaño que las señales EEG y ECG, primero se realizó una interpolación cúbica de la señal interpolada en función de su tiempo asociado. Luego, se creó un vector de tiempo con una frecuencia de muestreo de 250 Hz y se calcularon los valores interpolados para los nuevos tiempos, generando así una señal interpolada de longitud ajustada.

3.2.2.3 Obtención de VFC

Para extraer la VFC del ECG, es necesario seguir una serie de pasos fundamentales, los cuales abarcan desde la detección de los picos R hasta la identificación y eliminación de valores atípicos en el tacograma. Las etapas principales incluyen [36]:

- **Eliminar la línea de base:** para este procedimiento se implementó el filtro Butterworth de cuarto orden con una frecuencia de corte de 0.8 Hz [37].
- **Segmentación de onda R:** para resaltar el complejo QRS, se aplicó un filtro de paso de banda Butterworth de tercer orden en el rango de 5 a 20 Hz [38].
- **Detección de picos:** en este procedimiento se evaluaron múltiples algoritmos, entre los que se incluyen los detectores de Christov, WQRS, SWT, Hamilton, Pan Tompkins, Engzee y Two-average, disponibles en la biblioteca *Detectors* de Python [39]. Para establecer cuál de los algoritmos había detectado mejor los picos, se calcularon amplitudes de señal promedio en las posiciones donde se detectaron picos R. Si algún pico es detectado erróneamente, las amplitudes promedio disminuyen; por lo tanto, el algoritmo seleccionado es el que tiene el valor promedio más alto [40].
- **Corrección de picos:** en algunos casos la detección del pico R se desvía levemente de posición real, o algunas ondas del ECG se detectan como picos R. Para abordar esto, se empleó el corrector de picos de la biblioteca "wfdb" para Python [41].

- **Cálculo de TCG:** tras la identificación de las posiciones de los picos R, se procede al cálculo de la diferencia entre cada una de estas posiciones, que corresponde al tiempo entre picos R y se presenta como un valor en el TCG.
- **Preprocesamiento de TCG:** al obtener el TCG, se identifican comúnmente cuatro tipos de artefactos: latidos extra, latidos perdidos (no identificados), latidos ectópicos y valores atípicos. Estos artefactos pueden afectar el análisis posterior y, por lo tanto, deben ser eliminados o corregidos [29]. En este caso, se implementaron algoritmos que permitían detectarlos, basándose principalmente en el valor de la mediana del TCG (M-TCG), como se explica a continuación:

Latidos extra: se distinguen principalmente porque dos datos seguidos del TCG están por debajo de M-TCG, y la suma de estos valores es cercana a M-TCG. Esto ocurre cuando en medio de dos picos R, se detecta un pico incorrecto, por tanto, la diferencia entre estos es menor. Para corregir la presencia de un latido extra, se elimina un dato y el otro dato es reemplazado por la suma de los dos valores y en consecuencia el tamaño del TCG se reduce.

Latidos perdidos (no identificados): este tipo artefacto se presenta cuando no se han detectado picos RR. En consecuencia, la diferencia entre los picos R corresponderá, por ejemplo, al doble, triple o cuádruple (dependiendo de la cantidad de picos no detectados) de M-TCG. Se considera que hay latidos sin detectar, cuando hay datos en el TCG mayores de 1,5 veces M-TCG. Luego, para corregir este problema, siguiendo el método descrito en [42], se implementó un algoritmo que ajusta estos datos dividiéndolos en números enteros (dos, tres, cuatro, etc.) hasta que el resultado se asemeje al valor de M-TCG, y luego se agregan nuevos datos TCG según sea necesario.

Latidos ectópicos y valores atípicos: este tipo de artefactos se diferencian de los demás, porque en este caso se han detectado los picos correctamente, pero se observan datos en el tacograma que difieren significativamente del patrón normal. Para abordar esto, se aplicó un algoritmo fundamentado en [42], que involucra los siguientes pasos: primero, se calculan las diferencias entre valores sucesivos del TCG para crear la serie "drr". Luego, se estableció un umbral (U1) multiplicando el rango intercuartílico de "drr" por 5.2. Los valores de "drr" se ajustaron según este umbral y se identificaron como valores atípicos aquellos superiores a uno. En una segunda etapa, se creó la serie "mrr" restando el M-TCG del TCG original. Los valores de "mrr" se ajustaron con un umbral (U2) calculado de manera similar a U1 y se identificaron como atípicos aquellos superiores a uno. Este proceso se repitió cada 45 picos y los valores atípicos se corrigieron utilizando un modelo de

regresión basado en árboles de decisión, entrenado con el conjunto de datos original.

3.2.2.4 Descomposición de las señales

Las señales EEG (canal 1 y 2) y ECG, se descompusieron en seis bandas de frecuencia (lenta, delta, theta, alpha, beta y gamma) (Figura 6). Para este análisis, se implementó un filtro Butterworth pasabandas, comúnmente utilizado en el procesamiento de señales y se caracteriza por permitir el paso de señales dentro de un rango específico de frecuencias, mientras atenúa o elimina las señales fuera de ese rango. El filtro Butterworth se basa en la función de transferencia de un filtro analógico Butterworth [43]. Esta función de transferencia es una función racional de la frecuencia y se define por:

$$H(s) = \frac{1}{1 + \left(\frac{s}{\omega_c}\right)^{2N}} \quad (3)$$

Donde, ω_c es la frecuencia de corte, s es la frecuencia compleja y N el orden del filtro.

En este procedimiento, se diseñó un filtro Butterworth para cada banda de frecuencia requerida, utilizando la función `scipy.signal.butter`. Seguido de esto, se aplicó la función `scipy.signal.filtfilt`, que filtra la señal utilizando un filtrado bidireccional.

3.2.3 Extracción de características

La extracción de características es un procedimiento fundamental, que permite cuantificar los cambios que experimentan las señales, a través del análisis de diferentes dominios [44]. Para esta investigación, se extrajeron características a un total de 15 señales, que incluyen señales EEG, ECG, en las diferentes bandas de frecuencia y la VFC.

3.2.3.1 Características estadísticas

- **Media:** representa el valor central de un conjunto de datos y se calcula sumando todos los valores y dividiéndolos por el número total de elementos en el conjunto.
- **Moda:** es el valor que aparece con mayor frecuencia en un conjunto de datos.
- **Desviación estándar (std):** indica qué tan dispersos están los valores con respecto a la media. Se calcula como la raíz cuadrada de la media de los cuadrados de las desviaciones de cada valor respecto a la media.
- **Varianza (Var):** Es una medida de la dispersión de los valores en relación con la media.

- **Curtosis:** Mide qué tan agudo o achatado es el pico de la distribución de datos. Una curtosis alta indica una distribución más puntiaguda, mientras que una curtosis baja indica una distribución más achatada.
- **Oblicuidad (Skewness):** Indica la asimetría de la distribución de datos. Un valor positivo indica una cola más larga hacia la derecha, mientras que un valor negativo indica una cola más larga hacia la izquierda.
- **Tasa de cruce por cero:** Representa el número de veces que una señal cruza el eje de referencia.
- **Energía (Power):** Es una medida de la "fuerza" o la "potencia" en una señal discreta y se calcula sumando los cuadrados de los valores absolutos de cada muestra en la señal.
- **Parámetros de Hjorth:** son una serie de medidas utilizadas en el procesamiento de señales para caracterizar diferentes aspectos de la señal. Fueron propuestos por Bo Hjorth en 1970 como una forma de cuantificar ciertas propiedades estadísticas de las señales. Los tres parámetros principales son:
 - Actividad:* representa la potencia de la señal y se calcula como la varianza de la señal en el dominio temporal.
 - Movilidad:* indica la frecuencia media o la proporción de desviación estándar del espectro de potencia. Se obtiene calculando la raíz cuadrada de la razón entre la varianza de la primera derivada de la señal y la varianza de la señal original.
 - Complejidad:* refleja el cambio en la frecuencia de la señal. Se calcula comparando la similitud de la señal con una onda senoidal pura. Un valor más cercano a 1 indica que la señal es más similar a una onda senoidal.
- **Potencia relativa (Prel):** describe la cantidad total de energía en una banda de frecuencia.
- **Potencia absoluta (Pabs):** indica la importancia relativa de una banda de frecuencia en comparación con la señal completa.
- **Valor cuadrático medio (RMS):** indica la magnitud promedio de una señal variable en el tiempo. Se calcula elevando al cuadrado cada elemento de la señal. Luego, se calcula la media de estos cuadrados y finalmente, se toma la raíz cuadrada del resultado obtenido en el paso anterior.

3.2.3.2 Características caóticas (fractales)

Las características caóticas se refieren a ciertos atributos o propiedades de una señal que exhiben comportamientos típicos de sistemas dinámicos caóticos. En el contexto del procesamiento de señales, las características caóticas son aquellas que reflejan la complejidad intrínseca, la irregularidad y la sensibilidad a las condiciones iniciales de una señal. Estas características pueden revelar patrones no lineales, autosimilitud fractal y estructuras dinámicas complejas en la señal.

- **Dimensión fractal de Higuchi (HFD):** Se basa en la generación de nuevas formas de onda utilizando subsecuencias de la señal original, diferenciadas por un punto de origen y un factor de retardo discreto entre puntos. El cálculo implica la determinación de la longitud promedio de cada subsecuencia y su posterior análisis para encontrar si la relación entre esta longitud promedio y el factor de retardo sigue una ley de potencia, indicativa de un fractal, con una dimensión fractal (FD) específica [45].
- **Dimensión fractal de Petrosian (PFD):** Utiliza un algoritmo que convierte la serie de tiempo en una secuencia binaria para calcular rápidamente la dimensión fractal. La fórmula proporciona una estimación directa de la dimensión fractal basada en la longitud de la secuencia y el número de cambios de signo en la secuencia binaria.
- **Exponente de Hurst (HE):** Esta medida se utiliza para evaluar la auto-similitud y correlación en series de tiempo. El exponente de Hurst proporciona información sobre la presencia y grado de dependencia a largo plazo en la señal. Se calcula a partir del rango reescalado y el número de observaciones, ofreciendo una visión detallada de la estructura de correlación temporal de la señal.
- **Dimensión fractal de Katz (FKD):** es una medida utilizada para describir la complejidad de un conjunto de datos y es utilizada para analizar señales biológicas. Se calcula teniendo en cuenta el número total de puntos en la muestra, la longitud total de la curva obtenida sumando las distancias euclidianas entre puntos sucesivos, y la distancia máxima entre el primer punto y cualquier otro punto de la muestra.

3.2.3.3 Características basadas en entropía

Las características basadas en la entropía permiten determinar la regularidad y la variabilidad que presenta una señal. En este caso, el comportamiento no lineal de la entropía considera la complejidad de una señal y maximiza la capacidad de describir y diferenciar las señales de EEG ya que no son estacionarias por naturaleza [46]. Las entropías implementadas fueron:

- **Entropía de Rényi:** Es una medida generalizada de entropía que cuantifica la diversidad, incertidumbre o aleatoriedad de un sistema.
- **Entropía de Shannon:** mide la información promedio contenida en la función de distribución de probabilidad, que está relacionado con el grado de orden-desorden de una señal; señal aleatoria fuera del orden genera un valor significativo en la entropía.
- **Entropía aproximada (ApEn):** cuantifica la cantidad de regularidad y la imprevisibilidad de las fluctuaciones sobre los datos de series temporales. Esta se determina por la tendencia de la amplitud actual en relación con la amplitud anterior. Una alta regularidad produce valores más pequeños de ApEn, mientras que una baja regularidad produce valores más altos.
- **Entropía de la muestra (SampEn):** al igual que ApEn es una medida de complejidad, pero no incluye patrones de autosimilitud como en ApEn.
- **Entropía de descomposición de valores singulares (SVD):** es un indicador del número de vectores propios que se necesitan para una explicación adecuada del conjunto de datos. En otras palabras, mide la dimensionalidad de los datos.
- **Entropía espectral (SE):** se define como la entropía de Shannon de la densidad espectral de potencia (PSD) de los datos.

3.2.3.4 Características extraídas de la VFC

Para extraer características de la VFC, se empleó la librería *hrvanalysis*. Esta herramienta proporciona diversas funciones para obtener características en el dominio del tiempo, la frecuencia, características geométricas y no lineales:

Dominio del tiempo:

- Media de los intervalos RR (*media_nni*).
- Desviación estándar del intervalo de tiempo entre latidos cardíacos normales sucesivos (es decir, los intervalos RR) (*sdsd*).
- Desviación estándar de las diferencias entre intervalos RR adyacentes (*sdnn*).
- Raíz cuadrada de la media de la suma de los cuadrados de las diferencias entre intervalos NN adyacentes (*rmssd*): refleja influencias de alta frecuencia (rápidas o parasimpáticas) en la VFC (es decir, aquellas que influyen en cambios más grandes de un latido al siguiente).
- Valores absolutos medianos de las sucesivas diferencias entre los intervalos RR (*median_nni*).

- Número de diferencias de intervalo de intervalos RR sucesivos superiores a 50 ms (nni_50).
- Proporción derivada de dividir nni_50 (pnni_50, número de diferencias de intervalo de intervalos RR sucesivos mayores de 50 ms) por el número total de intervalos RR.
- Número de diferencias de intervalo de intervalos RR sucesivos superiores a 20 ms (nni_20).
- Proporción derivada de dividir nni_20 (pnni_20, número de diferencias de intervalo de intervalos RR sucesivos mayores de 20 ms) por el número total de intervalos RR.
- Diferencia entre el máximo y el mínimo nn_intervalo (rango_nni).
- Coeficiente de variación de diferencias sucesivas (cvsd) igual al rmssd dividido por mean_nni.
- Coeficiente de variación (cvnni): corresponde al cociente de sdn dividido por mean_nni.
- Frecuencia cardíaca media (mean_hr)
- Frecuencia cardíaca máxima (max_hr).
- Frecuencia cardíaca mínima (min_hr).
- Desviación estándar de la frecuencia cardíaca (std_hr).

Domino de la frecuencia:

- Densidad de potencia total espectral (potencia_total).
- Variación (potencia) en VFC en muy baja frecuencia (0.003 a .004 Hz) (vbf): Refleja un ritmo intrínseco producido por el corazón que es modulado principalmente por la actividad simpática.
- Variación (potencia) en VFC en la baja frecuencia (0.04 a 0.15 Hz) (bf): refleja una mezcla de actividad simpática y parasimpática, pero en registros a largo plazo, refleja actividad simpática y puede reducirse con el antagonista beta-adrenérgico propanolol.
- Variación (potencia) en VFC en la alta frecuencia (0.15 a 0.40 Hz por defecto) (af): refleja cambios rápidos en la variabilidad latido a latido debido a la actividad parasimpática (vagal). A veces se denomina banda respiratoria porque corresponde a los cambios de la VFC relacionados con el ciclo respiratorio y puede aumentar con la respiración lenta y profunda (alrededor de 6 o 7 respiraciones por minuto) y disminuir con fármacos anticolinérgicos o bloqueo vagal.

- Relación entre las bajas y altas frecuencias (relación_bf_af): Algunos investigadores utilizan a veces esta relación como un espejo cuantitativo del equilibrio simpático/vagal.
- Potencia bajas frecuencias normalizada (pbfn).
- Potencia de altas frecuencias normalizada (pafn).

Características geométricas:

- Medida del índice triangular (ind_triangular): es la integral de la distribución de densidad (= el número de todos los intervalos NN) dividida por el máximo de la distribución de densidad.
- Interpolación triangular del histograma de intervalo NN (ITNN): es el ancho de la línea de base de la distribución medida como la base de un triángulo, que se aproxima a la distribución de intervalo NN.

Características no lineales:

- Índice simpático cardíaco (CSI).
- Índice Vagal Cardíaco (CVI).
- El CSI modificado es una medida alternativa en la investigación de la detección de convulsiones (Modified_CSI).

3.2.4 Obtención del DataFrame

Después de realizar el procedimiento propuesto y extraer las características de cada señal, se generó un dataframe final. Sin embargo, con el objetivo de mejorar el rendimiento del modelo y evitar la inclusión de datos que puedan introducir ruido, se llevó a cabo un proceso de ajuste del dataframe. Esto implicó, el ajuste de los datos y la selección de las características más relevantes.

3.2.4.1 Ajuste de los datos

Una vez obtenido el dataframe, los datos fueron analizados y preprocesados, para garantizar su calidad y utilidad en los análisis posteriores. Este proceso incluyó una serie de pasos, diseñados para limpiar, estructurar y transformar los datos de manera que fueran aptos para su análisis:

- Eliminación de columnas categóricas con cardinalidad uno: se identificaron aquellas columnas categóricas que solo tenían un valor único en todo el conjunto

de datos. Estas eliminaron, ya que no proporcionaban información útil para el análisis.

- Codificación de variables categóricas: las variables categóricas restantes fueron codificadas adecuadamente para convertirlas en variables numéricas, para facilitar el procesamiento en modelos de *machine learning* y análisis estadísticos.
- Eliminación de columnas numéricas con varianza cero: se identificaron aquellas columnas numéricas que tenían una varianza igual a cero, lo que significa que todos los valores en esas columnas eran idénticos. Estas columnas se eliminaron porque no aportaban ninguna variabilidad al conjunto de datos.
- Identificación y eliminación de valores atípicos (*outliers*): Se realizaron análisis estadísticos y gráficos para detectar la presencia de valores atípicos en el conjunto de datos. Para eliminarlos, se implementó una arquitectura de red neuronal conocida como *autoencoder*. Esta red neuronal, aprende a representar y reconstruir datos, permitiendo así, identificar datos que se desvían notablemente de los patrones aprendidos durante el entrenamiento, ayudando a detectar posibles anomalías en el conjunto de los datos.
- Estandarización de los datos: Con el objetivo de mitigar cualquier influencia de la escala y la distribución de las características en el desempeño de los modelos, se realizó un preprocesamiento utilizando la técnica de escalado de características mediante la función de python *StandardScaler*.

3.2.4.2 Selección de características

La selección de las características es una de las fases más importantes, ya que desempeña un papel fundamental en la comprensión de los datos y en la construcción de modelos predictivos precisos y generalizables [47]. Para esta investigación seleccionaron las características más relevantes haciendo uso del método de *feature importance*, en cuatro modelos de aprendizaje automático ampliamente reconocidos e información mutua:

- Máquinas de Soporte Vectorial (SVM)
- Clasificador de árboles adicionales (ETC)
- Clasificador de bosque aleatorio (RFC)
- XGBoost (XGB)
- Información mutua (MI)

A partir de los atributos obtenidos por cada modelo, se compararon entre ellos y se seleccionaron las características que más se repitieron en los diferentes modelos (figura

12). Este proceso se llevó a cabo individualmente para cada una de las 15 señales analizadas en este estudio.

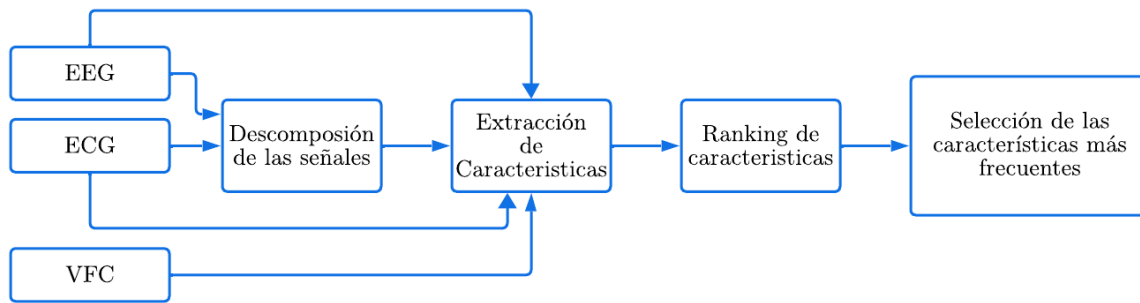


Figura 12. Procedimiento realizado para la selección de características más importantes

3.3 Modelado

En la etapa de modelado, se buscó implementar un modelo supervisado que permitiera la clasificación de diferentes estados del paciente (Figura 5), a través de la selección de técnicas de modelado, generando un plan detallado de pruebas, buscando los parámetros y técnicas para construir el modelo, y finalmente se evaluando su rendimiento.

3.3.1 Selección de técnicas de modelado

Se implementaron modelos supervisados, que permiten predecir el valor correspondiente a cualquier objeto de entrada y asignar una etiqueta [48]. Para esta investigación se tuvieron en cuenta cinco modelos de clasificación y cada estado del paciente se etiquetó con un valor, dependiendo del BIS (Tabla 3).

Tabla 3. Etiqueta de los estados del paciente.

Etap	BIS	Clase
Despierto	100-80	0
Sedación moderada	80-60	1
Anestesia general	60-40	2
Anestesia profunda	40-20	3

3.3.2 Generación del plan de pruebas

Al tratarse de un problema de clasificación con pacientes, se consideró dos tipos de clasificaciones: clasificación dependiente e independiente del paciente. Por consiguiente, se emplearon técnicas de validación cruzada estratificada que permiten una evaluación imparcial y robusta del rendimiento de los modelos. Específicamente, se utilizó *StratifiedKFold* para realizar la clasificación independiente del paciente y para la clasificación dependiente del paciente se empleó *StratifiedGroupKFold*, encontrados en la librería *Sklearn* de python.

3.3.3 Construcción del modelo

Para la construcción del modelo, se utilizó la técnica de *GridSearchCV* para realizar una búsqueda de los hiperparámetros óptimos para cada modelo (Tabla 4). *GridSearchCV* permite explorar sistemáticamente diferentes combinaciones de hiperparámetros mediante validación cruzada, lo que ayuda a optimizar el rendimiento de los modelos y evitar el sobreajuste [49].

Por otro lado, se utilizó la técnica de *VotingClassifier*, que combina múltiples estimadores de aprendizaje automático en un solo modelo, donde las predicciones se determinan por votación de la mayoría. Esta estrategia permite aprovechar las fortalezas de diferentes modelos individuales y mejorar la capacidad predictiva del conjunto.

Tabla 4. Parámetros utilizados para la búsqueda por grilla.

Algoritmos	Parámetros
KNN	{'n_neighbors': [5, 10, 15, 20]}
RFC	{'n_estimators': [50, 100, 150]}
ETC	{'n_estimators': [50, 100, 150]}
XGB	{'max_depth': [3, 5, 7], 'learning_rate': [0.1, 0.01, 0.001]}

3.3.4 Evaluación del modelo

Para proporcionar una evaluación integral del rendimiento de los modelos de clasificación, se consideraron diversas métricas, dentro de las que se encuentran:

- **Precisión:** es la proporción de instancias clasificadas correctamente como positivas entre todas las instancias clasificadas como positivas.
- **Accuracy (Acc):** es la proporción de instancias positivas que fueron correctamente clasificada sobre el número total de instancias evaluadas.
- **Recall:** es la capacidad del modelo para identificar correctamente las instancias positivas.
- **F1-score:** representa la media armónica entre precisión y el recall, que proporciona un balance entre ambas métricas.
- **Coefficiente kappa de Cohen (CKC):** es una medida de la concordancia entre las clasificaciones observadas y las esperadas por el azar, corregida para el acuerdo aleatorio.
- **Coefficiente de correlación de Matthews (MCC):** es una medida del grado de asociación entre las clasificaciones observadas y las esperadas.

- **Área bajo la curva ROC (AUC):** es una medida de la capacidad discriminativa del modelo, que representa la probabilidad de que el modelo clasifique correctamente una instancia positiva aleatoria por encima de una instancia negativa aleatoria.

3.4 Evaluación

En esta última etapa se analizó la pertinencia del modelo desarrollado con la relación entre el cerebro y el corazón. Para esta consideración, se tuvo en cuenta lo siguiente:

La relación entre el cerebro y el corazón se ha evaluado principalmente por métodos que involucran correlación, coherencia e interacción (sección 2.2). Por consiguiente, se planteó un procedimiento que involucró la obtención de características más relevantes y la clasificación de los estados del paciente a partir de ellas, para la identificación de patrones que permitan analizar la relación entre el cerebro y el corazón. Lo cual puede ser de gran ventaja ya que, durante la anestesia las señales EEG y ECG presentan diferentes variaciones y, en consecuencia, al considerar las características más notables, no solo permite reducir la dimensionalidad de los datos, sino también, centrarse en aquellas bandas de frecuencia que tienen una mayor capacidad para describir la relación entre la actividad cerebral y cardíaca.

Posteriormente, utilizando dicha información extraída, se llevó a cabo un análisis que involucró métodos no lineales como la teoría de la información mutua y la interdependencia no lineal. Estos métodos, han sido previamente utilizados en investigaciones para evaluar la relación entre el cerebro y el corazón. En el caso de la interdependencia no lineal, se enfoca en cómo estas señales interactúan de manera compleja y no lineal, es decir, cómo los cambios en una señal pueden provocar cambios no proporcionales o impredecibles en la otra señal. Por otra parte, el análisis de la información mutua proporciona una medida de la dependencia entre las señales, cuantificando cuánta información sobre una señal se puede inferir a partir de la otra. Esto permite evaluar la sincronización y la interconexión entre las señales, revelando patrones de correlación que no son evidentes con métodos lineales. Por lo tanto, con dicha información se clasificaron los estados de la anestesia nuevamente (Figura 13) y se comparó con lo obtenido con lo propuesto inicialmente.

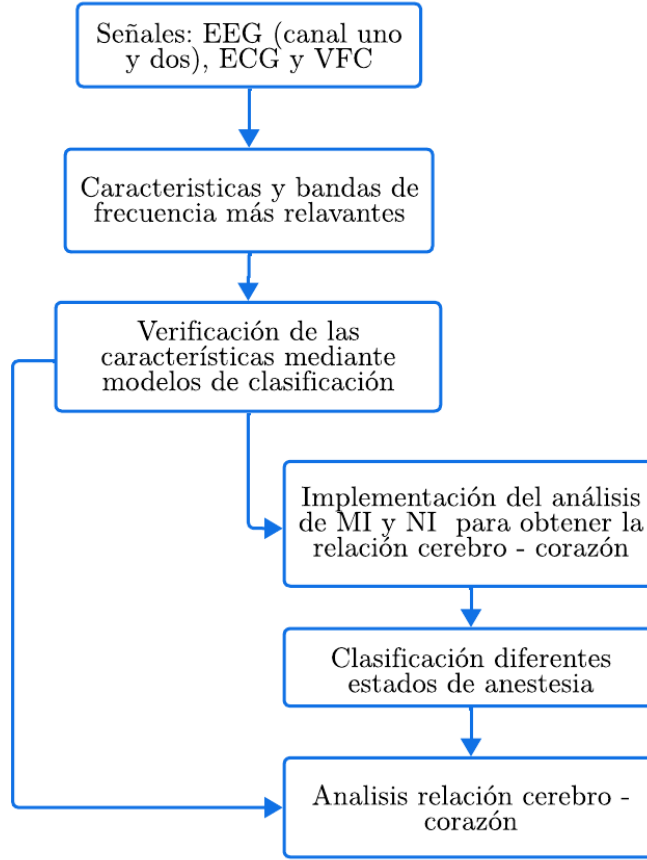


Figura 13. Procedimiento propuesto para el análisis de la relación cerebro-corazón (MI: información mutua, NI: Interdependencia no lineal)

3.4.1 Interdependencia no lineal

La interdependencia no lineal (NI), es una medida que proporciona la dirección de la sincronización entre dos sistemas X e Y . Se basa en la reconstrucción del espacio de estados de series temporales, el cual es un espacio abstracto en el que las diferentes variables que describen un sistema dinámico están representadas y cada punto en este estado representa un estado en el sistema. Para esto, cada sistema debe ser reconstruido en un vector de retraso $x_n = (x_n, \dots, x_{n-(m-1)\tau})$ e $y_n = (y_n, \dots, y_{n-(m-1)\tau})$, donde m , es la dimensión de incrustación y τ es el tiempo de retraso. Matemáticamente, la NI se expresa así [31]:

$$NI^{(k)}(X|Y) = \frac{1}{N} \sum_{n=1}^N \frac{Rn(X) - Rn^k(X|Y)}{Rn(X)} \quad (7)$$

Donde $Rn(X)$, es el radio cuadrado promedio de los valores reconstruidos en Xn y se define como:

$$Rn^{(k)}(X) = \frac{1}{k} \sum_{j=1}^k (x_n - x_{r_{n,j}})^2 \quad (8)$$

$Rn^k(X|Y)$ representa la distancia euclidiana cuadrada promedio condicionada a Y hacia sus k vecinos y se define como:

$$Rn^{(k)}(X|Y) = \frac{1}{k} \sum_{j=1}^k (x_n - x_{s_{n,j}})^2 \quad (9)$$

Si N es cercano a cero entonces X e Y son independientes y si es cercano a uno los sistemas están sincronizados. La relación conductor-respuesta se puede predecir a partir de que $NI(X|Y) > NI(Y|X)$, entonces sugiere que X conduce a Y [31].

3.4.2 Teoría de la información mutua

La información muta (MI), se basa en la descripción de la información obtenida sobre un sistema X y la medida de otro sistema Y , a través de la función de probabilidad de distribución entre ambos sistemas. Este análisis se ha aplicado para investigar la relación entre el cerebro y el corazón en el contexto de la apnea del sueño, con el fin de determinar si estos dos órganos son independientes o dependientes entre sí [31], [50]. Matemáticamente, se expresa de la siguiente manera:

$$MI_{XY} = \sum_{xy} P_{xy} \log \left(\frac{P_{xy}}{P_x P_y} \right) \quad (4)$$

Donde, P_{xy} es la función de probabilidad de distribución y P_x y P_y son las funciones de probabilidad de distribución marginal. Si X es independiente de Y , entonces el valor de la información mutua es igual a cero ($MI = 0$), y si los sistemas son dependientes el valor mayor a cero ($MI > 0$). Para normalizar los valores entre cero, se debe calcular la entropía conjunta $H(X, Y)$, que se define como:

$$H(X, Y) = \sum_{xy} P_{xy} \log(P_{xy}) \quad (5)$$

Por lo tanto, la MI normalizada (\overline{MI}_{XY}) se describe como:

$$\overline{MI}_{XY} = \frac{MI_{XY}}{H(X, Y)} \quad (6)$$

CAPÍTULO 4

4 RESULTADOS Y ANÁLISIS

En base a la metodología propuesta, en este capítulo se presentan los resultados, observaciones y los análisis en base a la información obtenida en cada uno de los experimentos y etapas planteadas.

4.1 Comprensión de los datos

Esta etapa, consistió principalmente en obtener una visión general de la información consignada en la base de datos.

4.1.1 Recolección de los datos

En la página web de *VitalDB* se encontró que contiene datos multiparamétricos de alta resolución de 6.388 casos de hombres y mujeres. La información se encuentra distribuida de la siguiente forma (Tabla 5):

Tabla 5. Descripción general de la base de datos.

Conjunto de datos	Cantidad	Descripción
Información clínica	73	Parámetros clínicos perioperatorios
Parámetros hemodinámicos	486.451	Registros de datos numéricos
	196	datos de forma de onda
Resultados de laboratorio	34	Parámetros de resultados de laboratorio de series temporales

La mayor cantidad de datos se encuentran registrados en los parámetros hemodinámicos, que contienen pistas de datos numéricos y datos de forma de onda.

Así mismo, la base de datos está agrupada principalmente en cuatro tipos de cirugía no cardíaca (general, torácica, ginecológica y urológica). Cada uno de estos tipos de cirugía, contiene información sobre: datos demográficos (sexo, edad, altura, y peso), abordaje quirúrgico (abierto, videoscópico, robótico), tipo de anestesia (general, espinal, sedación), duración la anestesia, anestésicos (Sevoflurano, Desflurano, Propofol TCI, Remifentanilo TCI) y los dispositivos utilizados (Tabla 6).

Tabla 6. Descripción específica de los parámetros registrados en la base de datos.

Categoría	Tipo	Cantidad de pacientes/ promedio
Tipos de Cirugía	Cirugía General	4.930
	Cirugía Torácica	1.111
	Ginecología	230
	Urología	117
Demográfico	Sexo (masculino)	3.243

	Años (edad)	59 (48-68)
	Altura (cm)	162 (156-169)
	Peso (kg)	61 (53-69)
Abordaje quirúrgico	Abierto	3.368
	Videoscópico	2.701
	Robótico	269
Anestesia	General	3.043
	Espinal	273
	Sedación	72
Duración anestesia	-	150 (90-240) min
Anestésicos	Sevoflurano	2.537
	Desflurano	1.383
	Propofol TCI	3.498
	Remifentanilo TCI	4.835
Dispositivos	Tram-Rac 4A (SNUADC)	6.355
	Solar 8000M	6.388
	Primus	6.362
	BIS Vista	5566
	Orchestra	4.919
	Vigileo	348
	EV1000	599
	Vigilance II	63
	CardioQ	29
	INVOSTM	33
	FMS2000	15

La base de datos también incluye información importante sobre los dispositivos empleados, como: el nombre para acceder a los datos, las unidades de medida y la frecuencia de muestreo. Para esta investigación se utilizaron los datos provenientes de los dispositivos *Tram-Rac 4A(SNUADC)* y *Vista BIS*, con los que se obtuvieron las señales EEG, BIS y ECG. De la señal ECG se tienen dos derivaciones (II y V5) y del EEG se tienen dos canales (canal 1 y 2) (Tabla 7).

Tabla 7. Dispositivos utilizados para grabar las señales EEG, BIS y ECG.

Dispositivo	Tipo de dispositivo	Parámetro	Descripción	Tipo/Hz	Unidad
Tram-Rac 4A (SNUADC)	Monitor de paciente	SNUADC/ECG_II	Onda de derivación II del ECG	W/500	mV
		SNUADC/ECG_V5	Onda V5 de derivación de ECG	W/500	mV
Vista BIS	Monitor de EEG	BIS/EEG1_WAV	Onda EEG del canal 1	W/128	uV
		BIS/EEG2_WAV	Onda EEG del canal 2	W/128	uV
		BIS	Valor del índice bispectral	Numérico	Sin unidad

4.1.2 Descripción de los datos

Posteriormente, se analizaron en detalle los datos correspondientes a la información clínica, parámetros hemodinámicos y resultados de laboratorio que estaban contenidos en DataFrames; esto se hizo con el fin de analizar los parámetros y características que contenía cada uno.

- DataFrame de información clínica: se obtuvo un dataframe de 6388 filas y 74 columnas. Las filas correspondían al número de pacientes y las columnas correspondían a diferentes parámetros que se tuvieron en cuenta antes, durante y después de la cirugía. Estos datos, permitieron conocer acerca del estado del paciente, grado de salud, los medicamentos que se administraron, tiempo que se duró la operación, la anestesia, el tiempo que el paciente estuvo en el hospital, los datos demográficos, resultados de laboratorio preoperatorios, datos durante la cirugía, incluso acerca de la mortalidad preoperatoria (Tabla 8).

Tabla 8. Parámetros encontrados en el DataFrame de información clínica.

Categoría	Número de parámetros	Descripción
Identificación	2	Estos parámetros hacen referencia al número de paciente y a una identificación de cuatro dígitos.
Información del expediente del caso	6	Estos datos dan información acerca de las horas de inicio y finalización de la grabación del caso, anestesia y de la cirugía.
Resultados	4	Esta información está relacionada con la hora de ingreso, de alta, con la duración de la estancia postoperatoria en la unidad de cuidados intensivos y la mortalidad hospitalaria.
Demográfico	5	Estas medidas permiten observar la edad del paciente, género, altura (cm), peso (kg) e índice de masa corporal (kg/m^2).
Cirugía y anestesia	9	Incluyen información acerca del sitio o tipo quirúrgico, diagnóstico, nombre de la operación, y abordaje quirúrgico, entre otros parámetros.
Morbilidad preoperatoria	4	Con esta información se conoce el grado de hipertensión, diabetes, arritmias y el grado de función pulmonar de los pacientes.
Datos de laboratorio preoperatorios	18	Datos relacionados al estado de la sangre como el nivel de hemoglobina, nivel de plaquetas, las presiones arteriales de oxígeno y dióxido de carbono y la concentración de bicarbonato.
Datos intraoperatorios	26	Información sobre evaluación del paciente, estimación de pérdidas y fluidos, como pérdida de sangre estimada y sobre medicación y drogas.

- **Parámetros hemodinámicos:** contiene 486449 filas y 3 columnas. El número de filas corresponde a la cantidad de equipos utilizados en cada paciente y las columnas corresponden a un identificador de caso (caseid), un nombre de seguimiento de datos (tname; nombre de dispositivo/nombre de parámetro) y un identificador de seguimiento hexadecimal de 40 dígitos (tid) que es una dirección única para un dato individual (Tabla 9). Con esa dirección se puede acceder a los datos recolectados por los dispositivos utilizados en cada paciente. Cada uno de estos, contiene una columna de tiempo y una columna con el nombre del equipo, una forma de acceder a esta información mediante el sitio web <https://api.vitaldb.net/{tid}>.

Tabla 9. Visualización del DataFrame de parámetros hemodinámicos

No.	caseid	tname	tid
0	1	BIS/BIS	fd869e25ba82a66cc95b38ed47110bf4f14bb368
1	1	BIS/EEG1_WAV	0aa685df768489a18a5e9f53af0d83bf60890c73
2	1	BIS/EEG2_WAV	ad13b2c39b19193c8ae4a2de4f8315f18d61a57e
3	1	BIS/EMG	2525603efe18d982764dbca457affe7a45e766a9
4	1	BIS/SEF	1c91aec859304840dec75acf4a35da78be0e8ef0
5	1	BIS/SQI	087670cd3f03109ff5028f268587a9801865afca
...

- **Resultados de laboratorio:** esta estructura tabular contiene 928.448 datos de series temporales para 34 análisis de sangre desde 3 meses antes de la cirugía hasta 3 meses después de la cirugía. En este conjunto de datos se observa la identificación del caso (caseid), tiempo de prueba (dt) (segundos según el inicio del caso), el nombre de la prueba (name) y el resultado de la prueba (result) (Tabla 10).

Tabla 10. Descripción del DataFrame

Índice	caseid	dt (s)	name	result
0	1	594.470	alb	2,9
1	1	399.575	alb	3,2
2	1	12.614	alb	3,4
3	1	137.855	alb	3,6
4	1	399.575	alt	12,0
5	1	137.855	alt	16,0
...

4.1.3 Exploración de los datos

Durante esta fase, se llevó a cabo un análisis inicial con datos de pacientes que cumplieran con criterios específicos. Estos criterios incluyeron procedimientos de cirugía general realizados bajo anestesia general, con el paciente en posición decúbito supino, y con monitoreo simultáneo de EEG (canal uno y dos), ECG (derivación II) y BIS. De los 6.388

pacientes inicialmente disponibles en la base de datos, 3.232 cumplían con todos estos criterios, para los cuales, se procedió a realizar los siguientes análisis:

Análisis 1: Análisis de ventanas de 60s de las señales en el inicio, mitad y final.

Una vez se obtuvo el conjunto de datos a considerar, se seleccionaron diez pacientes para analizar las señales de interés, EEG y ECG, mediante segmentos de 60s. Lo anterior, se logró extrayendo características conocidas (Sección 3.2.3), que permitieron observar el comportamiento de los órganos de interés durante diferentes momentos de la cirugía (antes, durante y después de la cirugía). Los principales resultados mostraron que las características en cada etapa se comportaban de manera diferente (Figura 14, 15 y 16), lo que da una idea que la actividad cerebral y cardíaca se comportan de manera diferente.

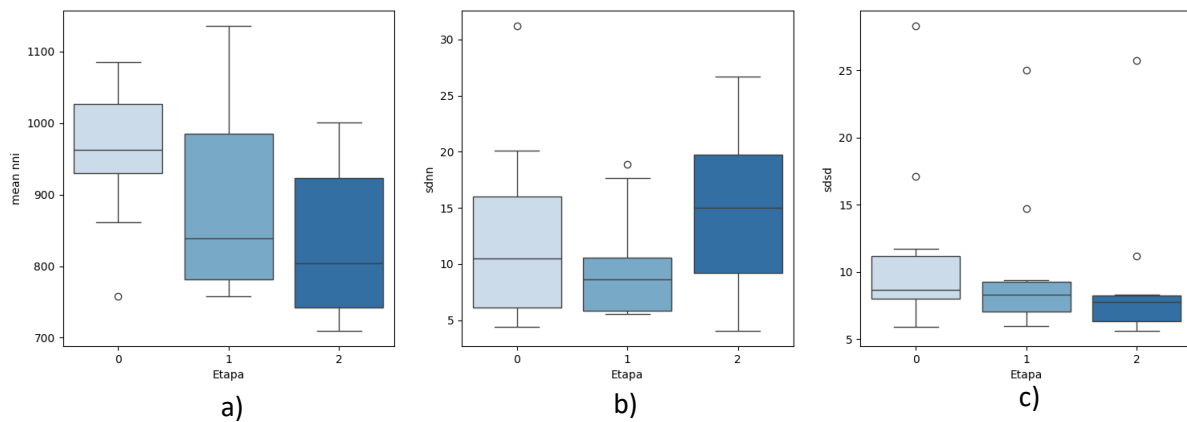


Figura 14. Análisis mediante box plot de algunas características de VFC: a) media de los intervalos RR (mean nni), b) desviación estándar del intervalo de tiempo entre latidos cardíacos normales sucesivos (sdrnn), c) desviación estándar de las diferencias entre intervalos RR adyacentes (sdsd).




Figura 15. análisis mediante box plot de algunas características del canal 1 de la señal EEG: a) entropía de muestra (SampEn), b) entropía espectral (SE), c) Entropía de descomposición de valores singulares (SVD)

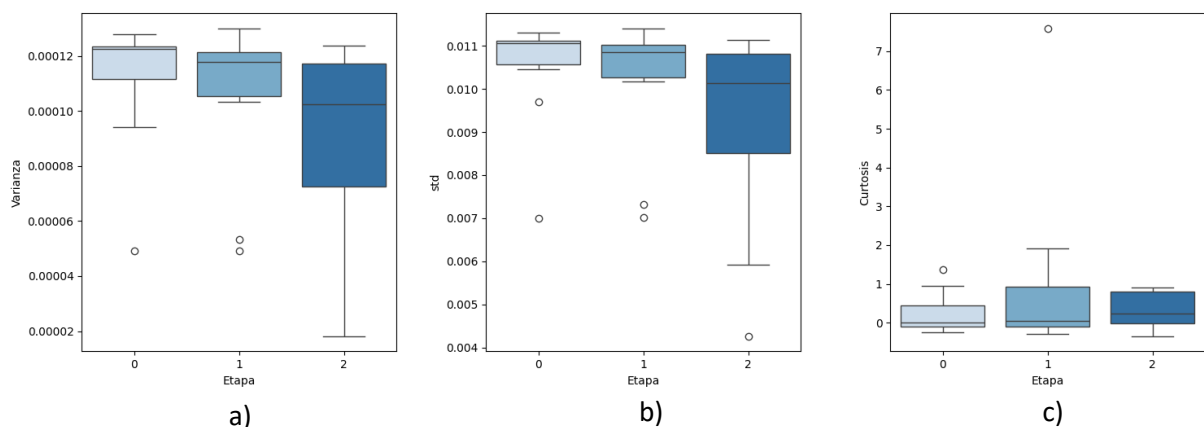


Figura 16. Análisis mediante box plots de algunas características del canal 2 de la señal EEG: a) varianza, b) std, c) vurtosis.

Análisis 2: Descripción estadística de los datos.

Este análisis, se enfocó en observar la distribución general de los datos demográficos como la edad, peso, altura (Tabla 11). También, se visualizó la cantidad de pacientes que había con diferentes tipos de ASA y tipo quirúrgico. Asimismo, se determinó la proporción de género, contabilizando 1.563 pacientes masculinos y 1.669 pacientes femeninos, proporcionando una visión general y resumida de los 3.231 pacientes inicialmente filtrados y permitió el establecimiento de criterios para poder seleccionar un subconjunto de datos más homogéneo (Sección 3.2.1).

Tabla 11. Descripción estadística de los datos demográficos de los 3232 pacientes.

Parámetro	Edad	Altura	Peso	IMC
Mean	56,60	161,74	60,95	23,18
std	15,09	10,68	12,34	3,76
min	0,30	42	4,80	11,30
25%	47	156	52,78	20,80
50%	58	161,90	59,95	23,00
75%	68	168,20	68,31	25,30
max	94	188,60	133,20	42,80

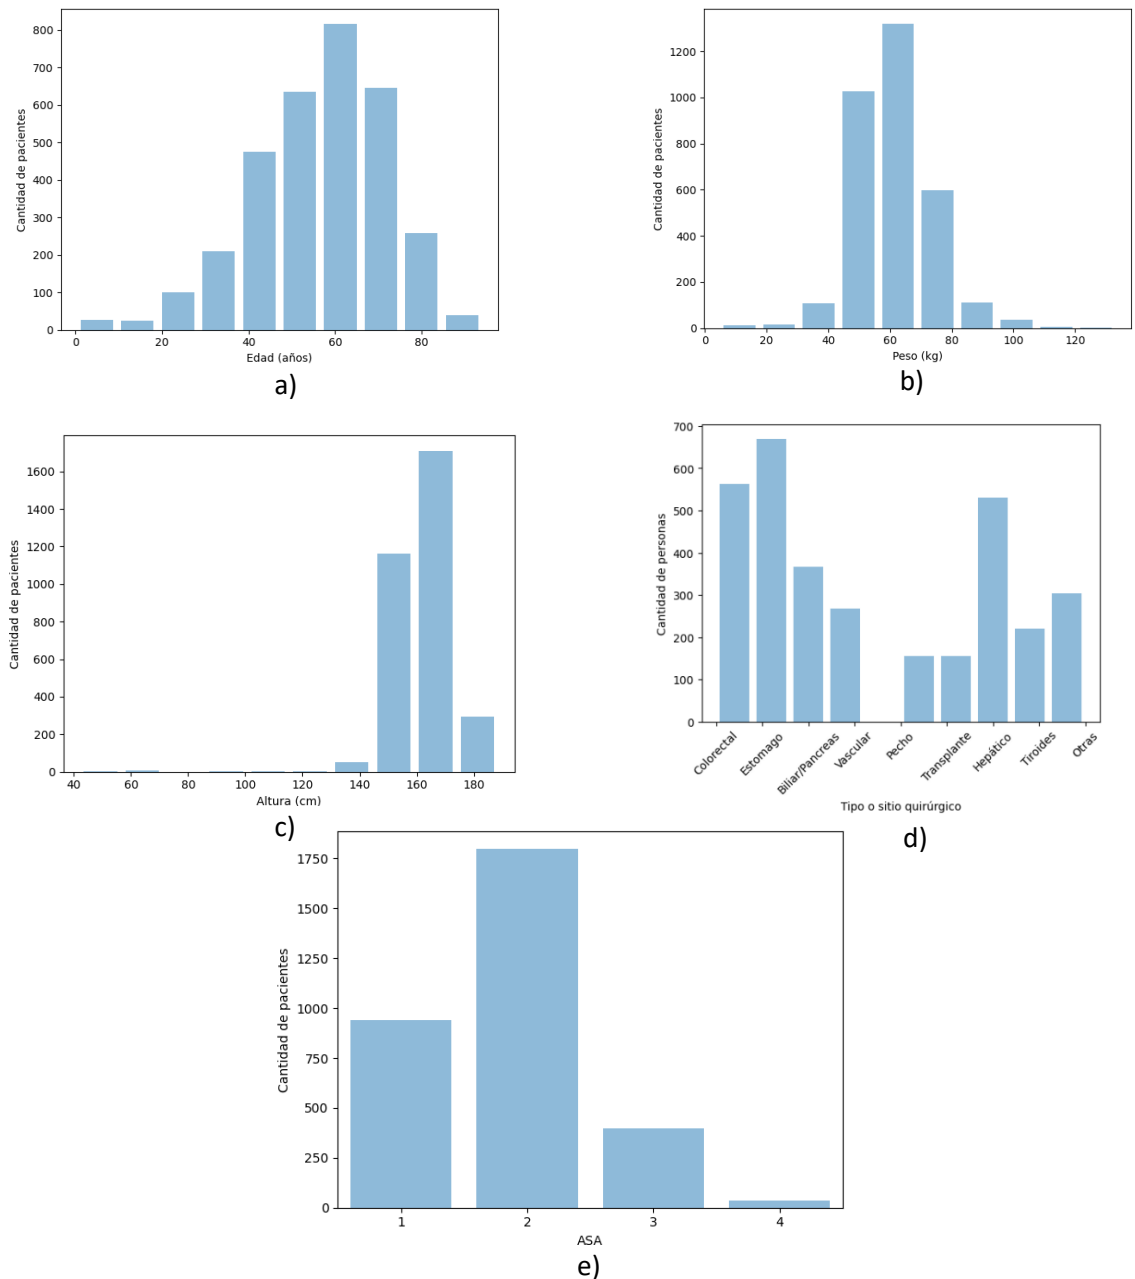


Figura 17. Distribución de Pacientes por: a) edad, b) peso, c) altura, d) tipo o sitio quirúrgico, e) ASA.

4.1.4 Verificación de la calidad de los datos

- Obtención de información del DataFrame y verificación de valores nulos:

Durante esta fase, se procedió a identificar los diversos tipos de datos contenidos en los distintos DataFrame. Entre los tres DataFrame analizados, se observó que únicamente el DataFrame de información clínica presentaba valores nulos (Tabla 12), que correspondían a algunos medicamentos y parámetros recopilados durante el procedimiento, que no eran relevantes para la investigación.

Tabla 12. Resultados del análisis de los DataFrame.

DataFrame	Tipo de Dato			Errores	
	float64	int64	object	Valores nulos	Valores infinitos
Información clínica	30	25	19	42.784	0
Parámetros hemodinámicos	-	1	2	0	0
Resultados de laboratorio	1	2	1	0	0

- Visualización de las señales sin preprocesamiento:

Durante esta etapa, se llevó a cabo la visualización de las señales de interés para identificar posibles problemas o artefactos en las señales. A continuación, se presentan algunos de los segmentos observados:




Figura 18. Segmento de buena calidad obtenido de la señal BIS.




Figura 19. Segmento de mala calidad obtenido de la señal BIS.




Figura 20. Segmento de buena calidad obtenido de la señal EEG canal dos.




Figura 21. Segmento de mala calidad obtenido de la señal EEG canal dos.




Figura 22. Segmento de buena calidad obtenido de la señal ECG.



Figura 23. Segmento de mala calidad obtenido de la señal ECG.

4.2 Preparación de los datos

En esta fase, se presenta los resultados del procedimiento que se llevó a cabo para obtener un Dataframe final para el análisis posterior. Esto comprendió desde selección del conjunto de pacientes a analizar, el resultado del preprocesamiento de las señales, la extracción de características, hasta la obtención del Dataframe final.

4.2.1 Selección de los datos

Después de implementar los criterios propuestos (Tabla 2), el número de pacientes a considerar fue 606. Con estos pacientes se obtuvo un Dataframe con 606 filas y 20 columnas. Cada fila representa a cada paciente y las columnas los datos que se tuvieron

en cuenta, como los dos canales de la señal EEG, la señal ECG, BIS y el tiempo que corresponde a la señal bis; también se tuvieron en cuenta datos demográficos, y los datos de morbilidad preoperatoria (Tabla 14).

4.2.2 Preprocesamiento de las señales

En esta sección, se muestran los resultados obtenidos tras el preprocesamiento realizado en las señales. Este proceso incluyó la selección de segmentos de buena calidad, filtrado para eliminar ruido y artefactos, y la obtención de la VFC.

4.2.2.1 Preprocesamiento de las señales EEG y ECG

Los pasos implementados para el procesamiento fueron los siguientes:

- **Selección de segmentos de buena calidad:** el algoritmo propuesto devuelve un diccionario que contiene datos de inicio y fin de cada segmento de buena calidad. Cada segmento está conformado por 15.000 muestras. Esta longitud está determinada por la frecuencia de muestreo de las señales y el tiempo de la ventana establecida para el análisis. Para ilustrar, los segmentos de buena calidad se identifican con uno, mientras que los de mala calidad se marcan con cero (Figura 24). Posteriormente, cada uno de estos segmentos se organizaron en un DataFrame para facilitar su análisis.

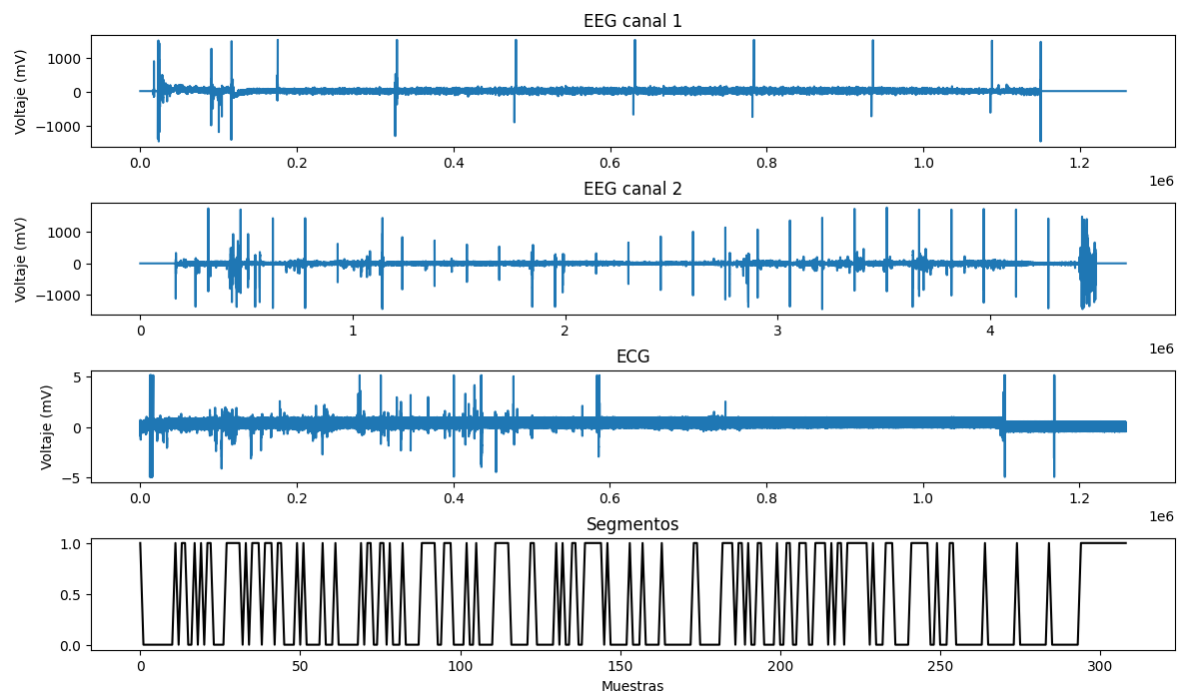


Figura 24. Selección de segmentos de buena calidad.

- **Filtrado Notch:** durante el análisis de las señales, se aplicó la transformada de Fourier, que permitió identificar la presencia de ruido a una frecuencia de 60 Hz

(figura 25.a). Para mitigar este efecto no deseado, se implementó el filtro Notch, que permitió la eliminación eficaz de dicho ruido (Figura 25.b).




Figura 25. a) Espectro de frecuencias de la señal EEG con ruido de 60 Hz, b) Espectro de frecuencias de la señal EEG después de eliminar el ruido de 60 Hz.

- **Suavizado de las señales:** se eliminaron ruidos de altas frecuencias (Figura 26, a), que generaban un rizado en la señal, sin alterar el comportamiento o cambiar la señal (Figura 26, b).




Figura 26. Eliminación del ruido de bajas frecuencias a) Segmento de la señal EEG sin el suavizado, b) Segmento de la señal EEG con el suavizado.

4.2.2.2 Preprocesamiento de la señal BIS

Durante el preprocesamiento de la señal BIS, se identificaron intervalos donde la señal experimentaba interrupciones (Figura 27.a). Estos datos faltantes, fueron estimados utilizando un modelo de regresión de árbol de decisiones, asegurando la continuidad de la señal y proporcionando así una representación completa y continua de los datos (Figura 27, b).




Figura 27. Segmento de la señal BIS a) sin procesar, b) después del procesamiento

4.2.2.3 Obtención de la VFC

Para la obtención de la VFC, se deben seguir los siguientes pasos: primero, se debe eliminar la línea de base (Figura 28) y resaltar el complejo QRS (Figura 29) para mejorar detección de los picos R. Seguido a esto, se detectan de los picos R (Figura 30), mediante algoritmos específicos y corregir dichas posiciones encontradas cuando no se han detectado en la mitad del pico R. Una vez hecho esto, se calcula la VFC (Figura 31), por medio de la diferencia entre las posiciones encontradas y se corrigen los valores atípicos, tal como se describe en la sección 3.2.2.3. Estos pasos adicionales son fundamentales para garantizar la precisión y la fiabilidad de los resultados de la VFC.




Figura 28. Comparación entre una señal ECG con línea de base (superior) y después de la corrección de la línea de base (inferior).




Figura 29. Segmento de la señal ECG, resaltando el complejo QRS.




Figura 30. Detección de los picos R en la señal ECG.




Figura 31. TCG obtenido después de detectar los picos R en la señal ECG.

Después de obtener el TCG, fue necesario tener en cuenta la corrección de artefactos que se estaban presentando:

Latidos extra: estos artefactos se caracterizan porque la diferencia entre picos detectados es menor que la mediana de las diferencias. En el ejemplo proporcionado, el TCG original consta de 89 datos (Figura 32.b), pero un pico que se detectó incorrectamente (Figura 32, rectángulo amarillo). Sin embargo, al aplicar el algoritmo propuesto, se corrige el TCG y su tamaño disminuye a 88 datos (Figura 32, rectángulo naranja).




Figura 32. Ejemplo de latido extra.

Latidos olvidados (no detectados): a diferencia de los latidos extra, estos se distinguen porque no se han detectado todos los picos (Figura 33, recuadro amarillo). En este caso, la diferencia entre los picos detectados antes y después del pico que no se detectó, será el doble de la mediana de las diferencias. Al aplicar el algoritmo propuesto, se observa que, en comparación con el tamaño del TCG original (79 datos), el tamaño corregido es mayor (80 datos - Figura 33, recuadro naranja).




Figura 33. Ejemplo de cuando no se detecta un pico R.

Latidos Ectópicos: a diferencia de otros tipos de artefactos, en los latidos ectópicos todos los picos R se detectan correctamente, pero se produce una anomalía en el TCG. Si bien el procedimiento para corregir estos artefactos es más complejo, el algoritmo propuesto demuestra su capacidad para detectar y corregir estos valores atípicos de manera adecuada (Figura 34).




Figura 34. Ejemplo de latido ectópico.

4.2.2.4 Descomposición de las señales

Las señales EEG y ECG se descompusieron a través del filtro propuesto, y en total se obtuvieron 12 señales adicionales.

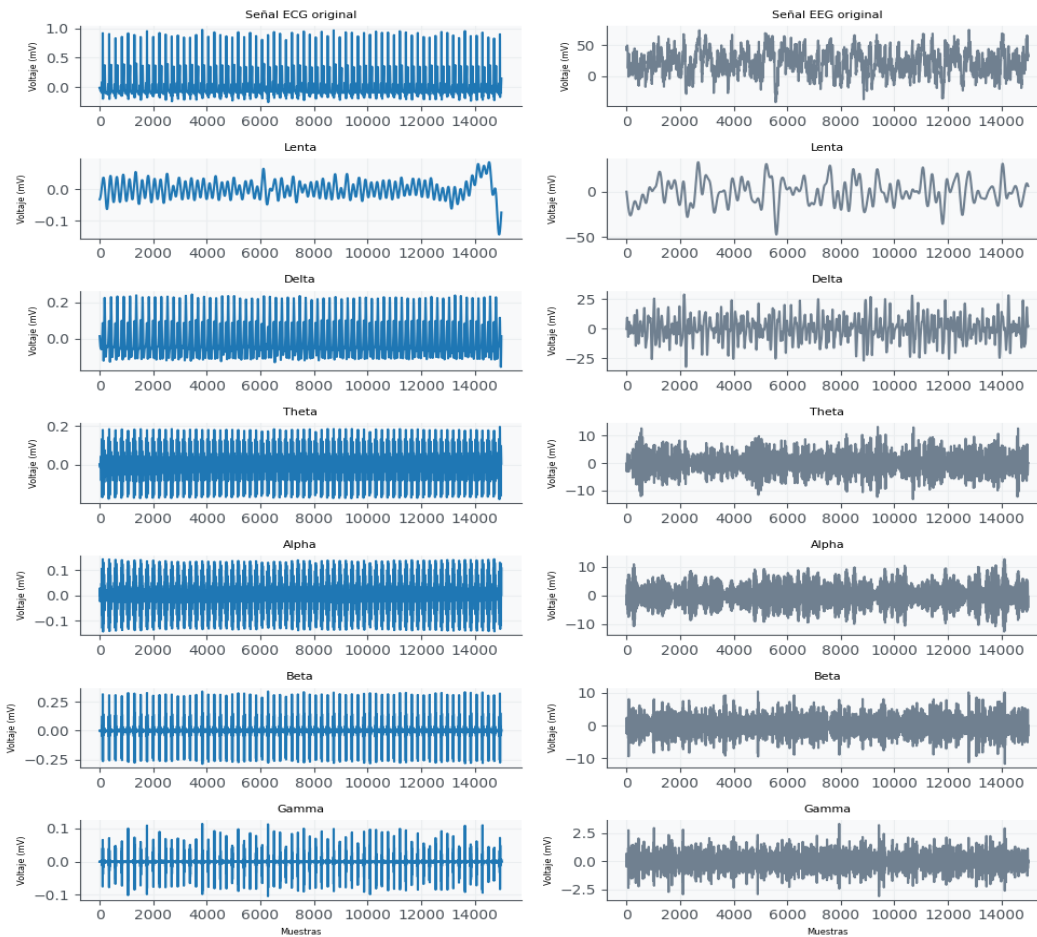


Figura 35. Descomposición de las señales en diferentes bandas de frecuencia.

4.2.3 Extracción de características

Durante el proceso de análisis, se llevó a cabo la extracción de características en varios dominios (Tabla 13), específicamente, se extrajeron un total de 58 características.

Tabla 13. Características extraídas a las señales EEG, ECG y VFC.

Características	Descripción	Total
Dominio del tiempo	Mínimo, máximo, media, mediana, moda, varianza, std, curtosis, ske, pow, tasa de cruce por cero, parámetros Hjorth, Prel, Pabs y RMS	16
Caóticas (Fractal)	FDH, PFD, HE, FKD	4
Entropía	Entropía Shannon, Entropía Renyi Entropía ApEn, Entropía SampEn, SVD, SE	6
Dominio del tiempo VFC	media_nni, sdnn, sdsd, rmssd, median_nni, nni_50, pnni_50, nni_20, pnni_20, rango_nni, cvsd, cvnni, media_hr, max_hr, min_hr, std_hr	15
Geométricas	medida del índice triangular, interpolación	2

	triangular del histograma de intervalo NN	
No-lineales	CSI, CVI y Modified_CSI	3
Dominio de la frecuencia VFC	lf, hf, lf_hf_ratio, lfnu, hfnu, total_power, vlf, tri_idx, tinn, sd1, sd2, ratio_sd2_sd1	12

4.2.4 Obtención del Dataframe (Estructura tabular de datos)

El DataFrame final utilizado en este estudio consta de 54.164 filas y 756 columnas, correspondientes a 606 pacientes, e incluye datos demográficos, información sobre la cirugía, detalles clínicos y características extraídas (véase Tabla 14).

- **Datos demográficos:** estos incluyen información como la edad, sexo, altura, peso e IMC de cada paciente.
- **Tiempo de inicio y fin de la operación:** registra los momentos de inicio y finalización de la cirugía.
- **Anestesia y registro del caso:** contiene información sobre el tiempo de inicio y finalización de la anestesia, así como el registro del caso.
- **Detalles de la cirugía:** incluye el tipo de operación, diagnóstico, posición del paciente durante la cirugía y el grado ASA.
- **Historial médico:** registra la presencia de hipertensión y diabetes en los pacientes antes de la operación.

Tabla 14. Descripción general del DataFrame final obtenido.

Categoría	Descripción
Identificación	Identificación para cada paciente de cuatro dígitos.
Información del expediente del caso	Tiempo de inicio de la operación
	Tiempo de cuando finalizó la operación
	Tiempo de inicio de la inducción de anestesia
	Tiempo de cuando finaliza de la inducción de la anestesia
Demográfico (promedio)	Edad: 57,29 ± 14,97 años
	Género: 195 hombres y 411 mujeres
	Altura: 160,18 ± 9,90 cm
	Peso: 61,48 ± 11,94 kg
	Índice de masa corporal: 23,27 ± 3,62 kg/m ²
Cirugía y Anestesia	Grado de ASA (1 y 2)
	Diagnóstico
	Nombre de la operación
	Sitio o tipo quirúrgico
Características extraídas	Dominio del tiempo
	Caóticas

	Entropía
	Geométricas
	No-lineales
	Dominio de la frecuencia

4.2.4.1 Ajuste de los datos

Se identificó si el Dataframe contenía datos que pudieran afectar el análisis, sin embargo, solo se encontró que los únicos datos a ajustar eran las variables de género (masculino y femenino) (Tabla 15). Además, se eliminaron valores atípicos utilizando un *autoencoder* para detectar los datos que se desviaban notablemente del resto (Figura 36), y finalmente se estandarizaron los datos para su posterior análisis.

Tabla 15. Información adicional sobre el Dataframe

Categoría	Descripción
Columnas categóricas con cardinalidad uno	Ninguna
Codificación de variables categóricas	M = 0, F = 1
Columnas numéricas con varianza cero	Ninguna
Columnas que no se tomaron en cuenta	Grado ASA Diagnóstico Nombre de la operación Sitio o tipo quirúrgico




Figura 36. Identificación de valores atípicos a) datos de varianza sin eliminar valores atípicos, b) datos de varianza después de eliminar valores atípicos.

4.2.4.2 Selección de características

En la selección de características, se aplicaron cuatro algoritmos de extracción de características y el método de información mutua, que proporcionaron los principales atributos, priorizando aquellas que se repetían con mayor frecuencia entre los distintos algoritmos. El propósito de este procedimiento fue observar cuáles de las 15 señales estaban aportando más información a la clasificación. Aunque se realizaron pruebas individuales con cada señal, al considerar la clasificación de manera conjunta se observaron mejoras significativas en el rendimiento, en comparación con las clasificaciones individuales. Los conjuntos se organizaron de la siguiente manera:

Grupo 1 - Señal EEG – canal 1 (señal completa y bandas de frecuencia): este grupo incluyó las principales características derivadas de la señal EEG del canal 1, así como de las diferentes bandas de frecuencia asociadas con dicho canal.

Grupo 2 - Señal EEG – canal 2 (señal completa y bandas de frecuencia): las principales características seleccionadas en este grupo fueron aquellas obtenidas de la señal EEG del canal 2, junto con las características de las diferentes bandas de frecuencia relacionadas con este canal.

Grupo 3 - Señal ECG (señal completa y bandas de frecuencia y VFC): se incluyeron las principales características extraídas de la señal ECG, así como de las diferentes bandas de frecuencia asociadas y VFC.

Grupo 4 - Combinación de Grupos 1 y 3: este grupo combinó las principales características de los Grupos 1 y 3, lo que proporcionó una representación más completa de la información fisiológica obtenida tanto de las señales EEG como de la señal ECG.

Grupo 1 - Señal EEG – canal 1 (señal completa y bandas de frecuencia):

El histograma (Figura 37) muestra que las bandas gamma, alpha y beta son las que más contribuyen a la clasificación de los estados de anestesia y las que menos aportan son las señales en las bandas theta y delta (Tabla 3). En cuanto a las características más relevantes, se observaron principalmente aquellas extraídas en el dominio del tiempo y las características caóticas (fractales), tales como la actividad, la energía, la varianza, la std, el Pabs, el RMS del espectro de potencia (RMS-espectro), y las señales Prel, PFD y HFD con diferentes parámetros de retraso (10, 50, 100). Por el contrario, las características menos representativas fueron las entropías (Samp, ApEn, SE) y el FKD (Figura 38).




Figura 37. Distribución de las señales en bandas de frecuencia del EEG (canal uno).




Figura 38. Tipos de características más relevantes obtenidas con el grupo 1.

Grupo 2 - Señal EEG – canal 2 (señal completa y bandas de frecuencia):

En este análisis, también se observaron comportamientos similares a los obtenidos con el grupo 1, en el que las ondas alpha, gamma, lenta y beta cumplen un papel importante en la clasificación (Figura 39).




Figura 39. Distribución de las señales en Bandas de frecuencia del EEG (canal dos).

Las principales características que se destacan también provienen del dominio del tiempo, caóticas y algunas entropías al igual que el grupo 1 (Figura 40).




Figura 40. Tipos de características más relevantes obtenidas con el grupo 2.

Grupo 3 – Señal ECG (señal completa, bandas de frecuencia y VFC): Este análisis difiere un poco a los anteriores, porque en este las características que más se repiten son las provenientes de las señales theta (Figura 41). Además, se observó que 18 de las 100 características provienen de la señal completa y pocas características de la VFC.




Figura 41. Distribución de las señales en bandas de frecuencia del ECG y VFC.




Figura 42. Tipos de características más relevantes obtenidas con el grupo 3.

Dentro de las características más destacadas obtenidas con el grupo 3 son: la varianza, movilidad, std y la entropía SVD, con frecuencias de 7 y 6 respectivamente. Mientras que algunas, como actividad, ske, SE y máximo, son menos frecuentes (Figura 42).

En general, los aspectos más relevantes para los tres grupos incluyen tanto variables del dominio del tiempo como medidas caóticas.

4.3 Modelado

4.3.1 Resultados del modelado de clasificación

El procedimiento que presentó mejores resultados implicó estratificar el conjunto de datos utilizando SGKF con cinco semillas (Figura 43), con cada uno de estos grupos se realizó la clasificación por votos, que se configuró con cuatro modelos de clasificación (KNN, RFC, ETC, XGB) y cuyos parámetros se identificaron utilizando búsqueda por grilla.




Figura 43. Representación del SGKF [51].

Cada uno de los grupos (sección 4.2.4.2), se evaluó de manera independiente para determinar su rendimiento en la clasificación de los datos, con el fin de identificar qué grupo de características resultaba más efectiva para la clasificación de los diferentes estados de anestesia.

Al utilizar búsqueda por grilla con los parámetros establecidos (Tabla 4), se determinó que el número de estimadores para RFC y ETC debía ser de 150. En contraste, para XGB, se ajustó la tasa de aprendizaje a 0,1 y la profundidad máxima a siete. Asimismo, para KNN, se observó que el rendimiento mejoraba al utilizar diez vecinos (Tabla 16).

Tabla 16. Parámetros obtenidos con la búsqueda por grilla para los clasificadores seleccionados para las señales EEG (canal uno y dos).

Clasificadores	Parámetros
KNN	n_neighbors=10
RFC	n_estimators=150
ETC	n_estimators=150
XGB	learning_rate= 0,1, max_depth=7

Clasificación con Grupo 1 - Señal EEG canal 1 - (señal completa y bandas de frecuencia):

Al utilizar SGKF, se obtuvieron resultados para cada uno de los grupos estratificados; por lo tanto, se presentan tanto los resultados individuales de un grupo como el promedio de todos ellos. El desempeño del modelo muestra valores de precisión, recall y f1-score de 0,82, indicando que el modelo está identificando de manera efectiva la clase positiva. Sin embargo, el CKC y MCC presentan valores de 0,65, lo que indica que el modelo está identificando de la clase positiva bien, pero podría estar cometiendo errores en la identificación de la clase negativa (Tabla 17).

Tabla 17. Resultados de la evaluación de la clasificación grupo 1

Métrica	Valor para un grupo	Valor Promedio
Accuracy	0,82	0,82
Precisión	0,82	0,82
F1-Score	0,82	0,81
Recall	0,82	0,82
CKC	0,67	0,66
MCC	0,67	0,66
AUC	0,95	0,95

Los resultados obtenidos con los datos provenientes de la actividad eléctrica cerebro muestran que las clases con mayor desempeño son la clase cero, dos y tres, lo que indica que esos estados de anestesia pueden ser mayormente diferenciados por los algoritmos, mientras que el estado de sedación moderada tiene un recall y un F1-Score menor a 0,6 (Tabla 18) y gran parte de los datos se clasifican en la clase dos (Figura 44).

Tabla 18. Reporte de clasificación por cada una de las clases

Clase	precision	recall	F1-Score	Cantidad de datos
0	0,68	0,93	0,79	116
1	0,83	0,42	0,55	544
2	0,83	0,85	0,84	5.739
3	0,82	0,83	0,83	4.425




Figura 44. Matriz de confusión para la clasificación de los datos provenientes del grupo 1.

Clasificación con Grupo 2 - Señal EEG canal 2 - (señal completa y bandas de frecuencia):

Respecto a los resultados obtenidos con este grupo se observó que el recall y F1-score están entre 0,79 y 0,80. Sin embargo, el CKC y el MCC son relativamente menores que la clasificación anterior, con un valor de 0,61 (Tabla 19).

Tabla 19. Resultados de la evaluación del grupo 2.

Métrica	Valor para un grupo	Valor Promedio
Accuracy	0,79	0,80
Precisión	0,79	0,80
F1-Score	0,79	0,80
Recall	0,78	0,80
CKC	0,61	0,63
MCC	0,61	0,63
AUC	0,94	0,94

Al igual que la clasificación con el grupo 1, las clases con mayor desempeño son la clase cero, dos y tres, mientras que la clase uno, tiene un recall menor a 0,6 (Tabla 20) y gran cantidad de los datos se clasifican en la clase dos (Figura 45).

Tabla 20. Reporte de clasificación por clase del grupo 2.

Clase	precision	recall	F1-Score	Cantidad de datos
0	0,69	0,90	0,79	156
1	0,77	0,47	0,58	573
2	0,79	0,82	0,81	5.674
3	0,79	0,78	0,78	4.422




Figura 45. Matriz de confusión para la clasificación de los datos provenientes del grupo 2.

Clasificación con Grupo 3 - Señal ECG - (señal completa, bandas de frecuencia y VFC):

Los resultados más destacados indican que el rendimiento sin utilizar SGKF es superior en comparación con el uso de SGKF (Tabla 21).

Tabla 21. Resultados de la evaluación del ECG y VFC.

Métrica	Sin Utilizar SGKF	Utilizando SGKF	
	Valor	Valor para un grupo	Valor promedio
Accuracy	0,79	0,58	0,58
Precisión	0,79	0,55	0,56
F1-Score	0,78	0,58	0,55
Recall	0,79	0,55	0,58
CKC	0,60	0,18	0,18
MCC	0,61	0,19	0,19
AUC	0,92	0,68	0,72

En el reporte de clasificación por clase, se observa que la clase dos tiene el mejor rendimiento con un f1-score de 0,82, mientras que la clase uno tiene el rendimiento más bajo con un f1-score de 0,36 (Tabla 22).

Tabla 22. Reporte de la evaluación de la clasificación por clase, sin utilizar SGKF.

Clase	precision	recall	F1-Score	Cantidad de datos
0	0,76	0,62	0,68	229
1	0,72	0,24	0,36	928
2	0,77	0,87	0,82	8.582
3	0,82	0,75	0,79	6.496




Figura 46. Matriz de confusión sin SGKF del grupo 3.

Reporte de clasificación del grupo 3 utilizando SGKF:

Respecto a la clasificación utilizando SGKF, las clases no son bien clasificadas y la mayoría de las clases se clasifican en la clase dos (Figura 47). Lo que a su vez implica que el rendimiento por clases sea demasiado bajo (Tabla 23), por lo tanto, se obtienen valores de CKC Y MCC muy pequeños (Tabla 21).

Tabla 23. Reporte de clasificación por clase del grupo 3, utilizando SGKF.

Clase	precision	recall	F1-Score	Cantidad de datos
0	0,62	0,19	0,29	155
1	0,21	0,01	0,02	617
2	0,59	0,73	0,66	5.727
3	0,55	0,46	0,50	4.333




Figura 47. Matriz de confusión utilizando SGKF.

Clasificación con Grupo 4 – principales características del grupo 1 y grupo 3:

El reporte de esta clasificación muestra que el f1-score y recall general aumentaron a 0,84, así como el CKC y MCC específicamente alcanzaron un valor superior a 0,70 respecto a la clasificación con las características de los anteriores grupos. Lo que sugiere que con la combinación de estas características, los modelos pueden clasificar mejor los cuatro estados de anestesia (Tabla 24).

Tabla 24. Resultados de la evaluación del grupo 4

Métrica	Valor para un grupo	Valor Promedio
Accuracy	0,84	0,82
Precisión	0,84	0,82
F1-Score	0,84	0,82
Recall	0,84	0,82
CKC	0,71	0,68
MCC	0,71	0,68
AUC	0,96	0,95

Al realizar la clasificación considerando las características más relevantes que describen tanto la actividad eléctrica del corazón como la del cerebro, se logró mejorar el rendimiento en todas las clases. En particular, la clase uno mostró una mejora significativa, donde el recall y f1-score aumentó a 0,61 y 0,71 respectivamente (Tabla 25). Lo anterior es notable, ya que, en las clasificaciones previas, el rendimiento que había presentado era bajo.

Tabla 25. Reporte de clasificación utilizando SGKF

Clase	precision	recall	F1-Score	Cantidad de datos
0	0,74	0,85	0,79	136
1	0,83	0,61	0,71	575
2	0,85	0,86	0,86	5.711
3	0,83	0,85	0,84	4.391




Figura 48. Matriz de confusión del grupo 4.

4.3.2 Análisis general de los resultados obtenidos:

En cuanto al análisis de la señal EEG (canal uno y dos) se consideraron dos tipos de clasificación, una dependiente e independiente del paciente. Específicamente, con la clasificación independiente del paciente se obtuvieron mejores rendimientos, sin embargo, para esta investigación se consideraron las clasificaciones dependientes del paciente, por ser un análisis más robusto y cercano a las condiciones que se presentan en el contexto clínico. Es importante destacar que, al considerar esta condición, la disminución en el rendimiento no fue tan significativa como se podría haber anticipado. Esto, sugiere que las características de mayor importancia y la metodología empleada son capaces de generalizar de manera efectiva a pesar de la variabilidad entre los pacientes.

Por otra parte, respecto a las bandas de frecuencia y la señal completa de la señal EEG con los canales uno y dos, se observó que los principales rendimientos para la clasificación dependiente e independiente del paciente se obtuvieron con las ondas alpha, beta y gamma, así como con la señal completa, indicando que las características provenientes de estas señales pueden contener información relevante y discriminativa para identificar los diferentes estados de la anestesia. Lo anterior concuerda con lo planteado en [16], en el que muestran que durante los diferentes estados de anestesia, se presentan dichas ondas y las características provenientes de ondas theta son menos relevantes para la clasificación (Figura 37 y 39).

Respecto a la señal ECG y a la VFC, cuando se realizó la clasificación utilizando SGKf el rendimiento fue bajo (Tabla 23), sugiriendo que la actividad eléctrica del corazón, representada por las características extraídas de las señales ECG y VFC, no evidencian patrones de comportamiento en los diferentes estados de anestesia para todos los pacientes, como en el caso de la actividad eléctrica del cerebro (EEG), que presenta diferentes patrones en los diferentes estados de anestesia (Figura 5). Por esta razón, cuando se realizó la clasificación dependiente del paciente, el modelo puede confundirse y como hay más datos de la clase dos, clasifica la mayoría de los datos en ella. Este comportamiento difiere considerablemente al realizar la clasificación de manera independiente del paciente y sin utilizar SGKf, puesto que se logran distinguir las diferentes clases, excepto la clase uno (Figura 46), sin embargo, esta clasificación no es tan robusta y podría estar utilizando datos del mismo paciente tanto para el entrenamiento como para la evaluación, y es posible que, para esos pacientes la actividad eléctrica del corazón varíe en las diferentes etapas y por ese motivo se obtengan buenos resultados de clasificación. Lo anterior, se pudo sustentar en base a los resultados de clasificación con EEG, que mostraron la capacidad de distinguir los estados de la anestesia, teniendo en cuenta el desbalance en las diferentes clases. Adicionalmente, se ha considerado que en contextos como la anestesia, la VFC puede presentar fluctuaciones significativas, debido a diferentes factores que la afectan como la pérdida de sangre y la hipotermia [52].

En contraste, el rendimiento de la clasificación basada en características tanto del corazón como del cerebro mejoró considerablemente (Tabla 24), especialmente en la clase uno (Tabla 25), la cual no se debe a la cantidad de atributos utilizados para la clasificación, sino al tipo de información que aportan, debido a que se evaluó el rendimiento de los modelos con diferentes cantidades de atributos. Por ejemplo, en la clasificación con los grupos 1 y 2, se consideraron distintas cantidades de características para observar hasta qué punto se mantenía el rendimiento, en cierto modo, se observó que al aumentar el número de atributos, el rendimiento de la clasificación no cambiaba significativamente, e incluso con la clase uno se seguía obteniendo rendimientos muy bajos.

En ese orden de ideas, los resultados obtenidos apuntan a que podría existir una relación entre las características del corazón y el cerebro, y que dicha relación al mismo tiempo cambia durante los diferentes estados de la anestesia, eso se vio reflejado al contemplar mejoras en el rendimiento de la clasificación considerando características provenientes de la actividad eléctrica de ambos órganos y podría ser importante para determinar la profundidad de la anestesia y otras aplicaciones más en este campo. Sin embargo, los resultados actuales no permiten llegar a una conclusión definitiva sobre esta relación, por lo que se requiere la implementación de otras técnicas para obtener una comprensión más completa.

4.4 Evaluación

Al combinar las características del EEG y del ECG y obtener una mejora significativa en la clasificación se podría sugerir una relación importante entre la actividad cerebral y cardíaca durante los diferentes estados de anestesia. El cerebro y el corazón están estrechamente interconectados a través del sistema nervioso autónomo, y esto se refleja con el mejoramiento del desempeño en la clasificación de los estados de anestesia. Durante diferentes estados de anestesia, es probable que haya cambios significativos en la actividad eléctrica cerebral y en la actividad eléctrica del corazón. Sin embargo, para poder corroborar esta hipótesis es necesario implementar el análisis de NI y MI que se han estudiado en otras investigaciones para obtener dicha relación.

4.4.1 Interdependencia no lineal (NI)

Para implementar la NI, primero se seleccionaron los parámetros necesarios (m , k y τ), en consecuencia, se analizó como el comportamiento de NI, variaba al considerar diferentes valores de los parámetros. Por lo tanto, primero se establecieron $\tau = 2$ y $k = 10$, y se variaron los valores de m (Figura 49.a). Así mismo, utilizando el mejor valor de m , se varió τ , manteniendo constante k (Figura 49.b) y finalmente, con los valores óptimos de m y τ , se modificaron los valores de k (Figura 49.c).




Figura 49. Variación de la NI con a) diferentes valores de m , b) diferentes valores de τ , c) con diferentes valores de k

Dentro de este estudio, se realizaron cuatro análisis que comprendieron combinaciones basadas en los resultados obtenidos previamente con los principales atributos (sección 4.2.4.2), (Tabla 26):

Tabla 26. Combinaciones de señales y sus representaciones para el análisis de NI y MI.

Análisis	Señal X	Representación	Señal Y	Representación
1	EEG (canal 1)	X1	ECG	Y1
2			VFC	Y2
3			ECG (theta)	Y3
4	EEG (gamma)	X2	ECG (gamma)	Y4

Posteriormente, los segmentos se agruparon dependiendo del estado de la anestesia y se determinó la mediana de los datos para cada grupo (Tabla 27).

Tabla 27. Valores de la mediana de NI entre diferentes combinaciones de señales

Estado	Análisis 1		Análisis 2		Análisis 3		Análisis 4	
	NI(X1 Y1)	NI(Y1 X1)	NI(X1 Y2)	NI(Y2 X1)	NI(X1 Y3)	NI(Y3 X1)	NI(X2 Y4)	NI(Y4 X2)
0	0,81	0,77	0,93	0,66	0,91	0,60	0,77	0,73
1	0,82	0,81	0,98	0,78	0,94	0,85	0,75	0,67
2	0,81	0,86	0,98	0,82	0,94	0,89	0,76	0,66
3	0,78	0,89	0,99	0,90	0,92	0,91	0,77	0,68

La NI, mostró que en todos los estados la interdependencia cambia considerablemente, lo que quiere decir, que las señales involucradas interactúan de manera compleja y no lineal, y los cambios en una señal pueden provocar cambios en la otra señal. En el caso del análisis 1 en los estados dos y tres, el valor de NI(Y1|X1) es mayor que NI(X1|Y1) lo que sugiere que el cerebro depende más de la actividad eléctrica del corazón, mientras que para las clases cero y uno NI(Y1|X1), es menor que NI(X1|Y1) lo que sugiere que el corazón depende más de la actividad eléctrica del cerebro durante estas etapas. Sin embargo, el mismo comportamiento no se observa en los otros tres análisis, donde se planteó explorar el comportamiento con las señales en las bandas de frecuencia que aportaban más información en la clasificación. Lo anterior sugiere, que este tipo de combinaciones deberían seguir siendo estudiadas a profundidad para poder analizar lo que puede estar sucediendo y cómo ciertas actividades cerebrales influyen en el ritmo cardíaco.

El análisis dos, que considera las señales EEG y VFC, NI(X1|Y2), proporcionó un valor mayor en comparación con los otros análisis, por consiguiente, una mayor interdependencia entre estas dos señales. Este comportamiento podría estar sucediendo porque el cerebro y el corazón están conectados a través de las ramas parasimpática y simpática del SNA, permitiendo que la actividad cerebral influya en la regulación del ritmo cardíaco y viceversa [4]. Por lo tanto, este tipo de análisis puede ser una medida indirecta de cómo varían las actividades simpática y parasimpática, proporcionando información importante sobre la comunicación corazón-cerebro durante los diferentes estados de la anestesia.

Por otra parte, al analizar los valores de NI, se observa que, para algunas combinaciones, el valor es diferente en cada estado (Tabla 27). Esto podría sugerir que, para determinar la profundidad de la anestesia, sería importante tener en cuenta el análisis de la relación cerebro-corazón. Sin embargo, cuando se realiza el análisis en dirección cerebro-corazón, se observa que los valores de las clases son iguales o cercanos entre sí, mientras que

cuando es en dirección corazón-cerebro la media de los valores es diferente entre las clases (Tabla 27, Análisis 1, columna $NI(Y1|X1)$). En general, los resultados coincidieron con los obtenidos en la clasificación del grupo 4, donde se observó un mejor rendimiento al incluir en el análisis las principales características que describen la actividad eléctrica tanto del corazón como del cerebro.

Asimismo, se observó cómo variaban los valores de la interdependencia no lineal para diferentes pacientes, por ejemplo, en algunos casos, la interdependencia considerando la dirección corazón-cerebro $NI(X|Y)$ era mayor que la dirección cerebro-corazón $NI(Y|X)$ (Figura 50.a). Sin embargo, para otros pacientes, estos valores fluctuaban a lo largo del tiempo, mostrando cambios en la dominancia de la dirección de interdependencia (Figura 50.b).




Figura 50. Variación de la interdependencia no lineal entre corazón y cerebro en diferentes pacientes. a) Ejemplo donde la interdependencia $N(X|Y)$ (corazón-cerebro) es mayor y se mantiene estable en el tiempo. b) Ejemplo donde los valores de interdependencia fluctúan, mostrando cambios en la dirección de la dominancia entre cerebro y corazón.

Lo anterior puede revelar que existen patrones específicos en la interacción entre el cerebro y el corazón, que podrían ser útiles en la detección temprana de complicaciones, profundidad de anestesia y pronóstico del postoperatorio del paciente. Sin embargo, es necesario evaluar este enfoque considerando más parámetros y condiciones durante la anestesia para obtener resultados fiables, y así proporcionar una herramienta adicional para el diagnóstico y monitoreo durante la anestesia.

4.4.2 Teoría de la información mutua

El análisis de la MI, para los diferentes estados de anestesia fue diferente de cero, lo que quiere decir, ambos órganos son dependientes y los valores presentan cambios en el estado y del tipo de señales que se analicen. En este caso, los valores de MI más altos corresponden al análisis con EEG y VFC (Tabla 28, análisis dos) y se observó la diferenciación entre clases, al igual que el análisis tres. Además, el valor más bajo se observa en el estado cero, mientras que el más alto se encuentra en el estado tres (Tabla 28, análisis dos y tres). Por otra parte, cuando se consideran las señales completas EEG y

ECG no se diferencian los valores de la mediana entre las clases cero y uno (Tabla 28, análisis uno).

Tabla 28. Valores de la mediana de la teoría de la información mutua entre diferentes estados

Estado	Análisis 1	Análisis 2	Análisis 3	Análisis 4
	MI1	MI2	MI3	M4
0	0,22	0,31	0,25	0,14
1	0,22	0,45	0,28	0,13
2	0,24	0,49	0,30	0,12
3	0,26	0,59	0,32	0,11

En consecuencia, los resultados obtenidos podrían respaldar la idea de que la actividad cerebral y cardíaca están relacionadas durante los diferentes estados de anestesia. Esto sugiere que los cambios en la relación entre el cerebro y el corazón pueden servir como biomarcadores importantes para la monitorización y el seguimiento de los pacientes durante la anestesia.

Análisis relación cerebro-corazón

Posteriormente, se planteó clasificar los diferentes estados de anestesia, desde un enfoque diferentes, utilizando los datos de IM y NI de todos los segmentos de las señales EEG y ECG, aplicando los cuatro análisis propuestos (Tabla 26). Al implementar el modelo de clasificación, se obtuvo un F1-Score y un recall de 0.69 (Tabla 29), mostrando que las clases pudieron ser diferenciadas considerablemente, excepto la clase uno (Tabla 30). Esto puede deberse a que en ese estado (sedación moderada), la relación entre el cerebro y el corazón sea muy similar a el estado de anestesia general, dificultando la diferenciación por parte del modelo. Este hallazgo concuerda con el análisis anterior de MI (Tabla 28) y NI (Tabla 27), que muestra que en algunos casos los valores de ese estado son cercanos a los de la clase dos. En el caso de NI, esta similitud ocurre cuando se analiza en la dirección cerebro-corazón en los cuatro análisis. Sin embargo, cuando se realiza la NI en la dirección corazón-cerebro, los valores en cada estado son diferentes, lo que indica que este aspecto debe ser evaluado con mayor profundidad y considerando más información.

Tabla 29. Resultados de la evaluación de la clasificación considerando datos de IM y NI

Métrica	Valor para un grupo	Valor Promedio
Accuracy	0,69	0,70
Precisión	0,70	0,70
F1-Score	0,69	0,69
Recall	0,69	0,70
CKC	0,43	0,44
MCC	0,43	0,44
AUC	0,87	0,87

Tabla 30. Reporte de clasificación por cada una de las clases

Clase	precision	recall	F1-Score	Cantidad de datos
0	0,62	0,82	0,71	120
1	0,75	0,23	0,35	572
2	0,71	0,72	0,72	5711
3	0,68	0,71	0,69	4589




Figura 51. Matriz de confusión de la clasificación considerando datos de IM y NI

CAPÍTULO 5

5 CONCLUSIONES Y TRABAJO FUTURO

La implementación de algoritmos de clasificación permitió analizar cómo se comporta el cerebro y corazón durante diferentes estados de la anestesia. Esto sugirió que la relación entre dichos órganos varía según los estados de la anestesia y se vio reflejado en los valores de las métricas evaluadas, en donde el rendimiento de cada una de las clases aumentó considerablemente en comparación cuando solo se realizaba la clasificación por separado. Un ejemplo de ello se observó en los valores de recall y F1-score de la clase uno (sedación moderada) que pasaron de ser 0,42 y 0,55 e incrementaron a 0,61 y 0,71, respectivamente, demostrando el dinamismo de la relación cerebro-corazón en contextos de anestesia.

Desde el punto de vista médico, analizar la relación entre ambos órganos, aun sigue siendo una tarea difícil, porque ambos se comportan de una manera compleja y no lineal, sin embargo, desde el punto de vista de la ingeniería, los algoritmos de clasificación revelaron que la señal ECG en el rango theta y el EEG en el rango gamma aportaron información adicional a la clasificación, por lo tanto, fueron utilizadas para implementar

diferentes análisis de MI y NI, que permitieron corroborar la hipótesis planteada, ya que se observaron cambios en los diferentes estados de la anestesia. Aunque estos resultados requieren de más investigación, la metodología empleada proporciona una idea de cómo varía la relación cerebro-corazón durante la anestesia.

Se evidenció la necesidad de implementar análisis no lineales debido al comportamiento no lineal y caótico de las señales EEG y ECG. Esto se demostró en diversos experimentos realizados, donde los métodos lineales no lograron identificar cambios en los diferentes estados de la anestesia. En contraste, el análisis no lineal permitió determinar si ambos órganos eran dependientes en todos los estados, y la información proporcionada por estos métodos sirvieron como atributos para clasificar los diferentes estados de la anestesia, subrayando la importancia de este enfoque en el estudio de su relación.

La clasificación considerando los atributos de interdependencia no lineal e información mutua permitió observar que, para los estados de despierto, anestesia profunda y general, los datos eran diferentes y podían ser identificados. Sin embargo, para el caso del estado de sedación moderada, la mayoría de los datos se clasificaron en anestesia general, lo que sugiere que en ese estado la relación entre ambos órganos no cambia y se comporta de la misma manera que cuando el paciente está en el estado de anestesia general.

Trabajo futuro

Dentro de los trabajos futuros, se plantea que podría ser útil seguir investigando la relación entre el cerebro y el corazón, pero de manera más robusta, incluyendo datos como la presión arterial, la frecuencia cardíaca, la saturación de oxígeno y otros biomarcadores para enriquecer el análisis y proporcionar una visión más completa del estado del paciente antes, durante y después de la anestesia. Además, en esta investigación, se analizaron datos de pacientes coreanos, por lo que sería de gran interés aplicar este tipo de análisis en pacientes colombianos para evaluar posibles diferencias culturales, genéticas o ambientales que puedan influir en la respuesta a la anestesia. Pero sobre todo se desea fomentar este tipo de investigaciones que impliquen una colaboración interdisciplinaria, para fomentar la colaboración entre anestesiólogos, cardiólogos, neurólogos e ingenieros. Con esto se busca mejorar la comprensión de la relación cerebro – corazón durante la anestesia y su impacto en el paciente.

Recomendaciones

Para mejorar la calidad y profundidad de los estudios sobre la relación cerebro-corazón durante diferentes estados de la anestesia y cirugía, se sugiere ampliar el enfoque del estudio para incluir la comunicación química y hormonal entre el cerebro y el corazón, utilizando biomarcadores específicos, así como incorporar técnicas de imagen avanzadas como fMRI y PET. Además, utilizar un registro EEG con más electrodos permitirá captar información de todas las regiones cerebrales, mejorando la comprensión de la actividad

cerebral durante la anestesia. Finalmente, para enriquecer el análisis se deberían incluir datos adicionales como presión arterial, frecuencia cardíaca, saturación de oxígeno y otros parámetros hemodinámicos y clínicos.

6 REFERENCIAS

- [1] R. McCraty, *Science of the heart: exploring the role of the heart in human performance*. Boulder Creek, Calif.: HeartMath Research Center, Institute of HeartMath, 2015.
- [2] N. D. Osteraas y V. H. Lee, «Neurocardiology», en *Handbook of Clinical Neurology*, vol. 140, Elsevier, 2017, pp. 49-65. doi: 10.1016/B978-0-444-63600-3.00004-0.
- [3] D. Sattin *et al.*, «Analyzing the Loss and the Recovery of Consciousness: Functional Connectivity Patterns and Changes in Heart Rate Variability During Propofol-Induced Anesthesia», *Front. Syst. Neurosci.*, vol. 15, p. 652080, abr. 2021, doi: 10.3389/fnsys.2021.652080.
- [4] N. Bahador y J. Kortelainen, «A Robust Bimodal Index Reflecting Relative Dynamics of EEG and HRV With Application in Monitoring Depth of Anesthesia», *IEEE Trans. Neural Syst. Rehabil. Eng.*, vol. 29, pp. 2503-2510, 2021, doi: 10.1109/TNSRE.2021.3128620.
- [5] J. Viegas, «Profile of Emery N. Brown», *Proc. Natl. Acad. Sci.*, vol. 119, n.º 47, p. e2215827119, nov. 2022, doi: 10.1073/pnas.2215827119.
- [6] «La función del anestesiólogo.», Anestesia. [En línea]. Disponible en: <https://www.anestesia.com/la-funcion-del-anestesiologo/>
- [7] A. M. Bastos *et al.*, «Neural effects of propofol-induced unconsciousness and its reversal using thalamic stimulation», *eLife*, vol. 10, p. e60824, abr. 2021, doi: 10.7554/eLife.60824.
- [8] G. Lichtner *et al.*, «Nociceptive activation in spinal cord and brain persists during deep general anaesthesia», *Br. J. Anaesth.*, vol. 121, n.º 1, pp. 291-302, jul. 2018, doi: 10.1016/j.bja.2018.03.031.
- [9] A. H. Khandoker, C. K. Karmakar, y M. Palaniswami, «Interaction between sleep EEG and ECG signals during and after obstructive sleep apnea events with or without arousals», en *2008 Computers in Cardiology*, Bologna, Italy: IEEE, sep. 2008, pp. 685-688. doi: 10.1109/CIC.2008.4749134.
- [10] H. Abdullah, N. C. Maddage, I. Cosic, y D. Cvetkovic, «Cross-correlation of EEG frequency bands and heart rate variability for sleep apnoea classification», *Med. Biol. Eng. Comput.*, vol. 48, n.º 12, pp. 1261-1269, dic. 2010, doi: 10.1007/s11517-010-0696-9.
- [11] D. Piper, K. Schiecke, B. Pester, F. Benninger, M. Feucht, y H. Witte, «Time-variant coherence between heart rate variability and EEG activity in epileptic patients: an advanced coupling analysis between physiological networks», *New J. Phys.*, vol. 16, n.º 11, p. 115012, nov. 2014, doi: 10.1088/1367-2630/16/11/115012.
- [12] H.-C. Lee, Y. Park, S. B. Yoon, S. M. Yang, D. Park, y C.-W. Jung, «VitalDB, a high-fidelity multi-parameter vital signs database in surgical patients», *Sci. Data*, vol. 9, n.º 1, p. 279, jun. 2022, doi: 10.1038/s41597-022-01411-5.

- [13] E. M. 27 Ramon Soto 2022, «La metodología Crisp-DM». [En línea]. Disponible en: <https://www.bi5on.com/blogs/entry/41-la-metodolog%C3%ADa-crisp-dm/>
- [14] E. N. Brown, R. Lydic, y N. D. Schiff, «General Anesthesia, Sleep, and Coma», *N. Engl. J. Med.*, vol. 363, n.º 27, pp. 2638-2650, dic. 2010, doi: 10.1056/NEJMra0808281.
- [15] E. N. Brown, K. J. Pavone, y M. Naranjo, «Multimodal General Anesthesia: Theory and Practice», *Anesth. Analg.*, vol. 127, n.º 5, pp. 1246-1258, nov. 2018, doi: 10.1213/ANE.0000000000003668.
- [16] P. L. Purdon, A. Sampson, K. J. Pavone, y E. N. Brown, «Clinical Electroencephalography for Anesthesiologists», *Anesthesiology*, vol. 123, n.º 4, pp. 937-960, oct. 2015, doi: 10.1097/ALN.0000000000000841.
- [17] T. Mitchell-Hines, K. Ellison, y S. Willis, «Uso de monitorización del índice biespectral para medir la profundidad de la sedación/analgésia», *Nurs. Ed Esp.*, vol. 33, n.º 6, pp. 38-41, nov. 2016, doi: 10.1016/j.nursi.2016.11.012.
- [18] E. N. Marieb, *Anatomía y fisiología humana*. Madrid: Pearson Addison Wesley, 2012.
- [19] S. Govoni, P. Politi, y E. Vanoli, Eds., *Brain and Heart Dynamics*. Cham: Springer International Publishing, 2020. doi: 10.1007/978-3-030-28008-6.
- [20] A. T. Mazzeo, E. La Monaca, R. Di Leo, G. Vita, y L. B. Santamaria, «Heart rate variability: a diagnostic and prognostic tool in anesthesia and intensive care: Heart rate variability and anesthesiologist», *Acta Anaesthesiol. Scand.*, vol. 55, n.º 7, pp. 797-811, ago. 2011, doi: 10.1111/j.1399-6576.2011.02466.x.
- [21] W. Srimaharaj, R. Chaisricharoen, S. Chaising, y P. Sittiprapaporn, «Classification of human brain attention focused on meditation, effected by L-theanine acid in Oolong tea», en *2018 International Conference on Digital Arts, Media and Technology (ICDAMT)*, Phayao: IEEE, feb. 2018, pp. 262-266. doi: 10.1109/ICDAMT.2018.8376536.
- [22] R. McCraty, A. Mike, D. Tomasino, y R. Bradley, «The Coherent Heart Heart–Brain Interactions, Psychophysiological Coherence, and the Emergence of System-Wide Order», *Integral Rev.*, vol. 5, dic. 2009.
- [23] W. Liu, X. Zhang, Z. Wu, K. Huang, C. Yang, y L. Yang, «Brain–heart communication in health and diseases», *Brain Res. Bull.*, vol. 183, pp. 27-37, jun. 2022, doi: 10.1016/j.brainresbull.2022.02.012.
- [24] «ECG interpretation: Characteristics of the normal ECG (P-wave, QRS complex, ST segment, T-wave)». [En línea]. Disponible en: <https://ecgwaves.com/topic/ecg-normal-p-wave-qrs-complex-st-segment-t-wave-j-point/>
- [25] «Efecto de la estimulación simpática y parasimpática sobre la frecuencia cardíaca». [En línea]. Disponible en: <https://homomedicus.com/efecto-de-la-estimulacion-simpatica-y-parasimpatica-sobre-la-frecuencia-cardiaca/>
- [26] D.-K. Kim, K.-M. Lee, J. Kim, M.-C. Whang, y S. W. Kang, «Dynamic correlations between heart and brain rhythm during Autogenic meditation», *Front. Hum. Neurosci.*, vol. 7, 2013, doi: 10.3389/fnhum.2013.00414.
- [27] «¿Qué es la inteligencia artificial (IA)?» [En línea]. Disponible en: <https://aws.amazon.com/es/machine-learning/what-is-ai/>
- [28] R. Polepogu y N. K. Vaegae, «Signal Processing Techniques for Coherence Analysis Between ECG and EEG Signals with a Case Study», en *Congress on Intelligent Systems*,

- vol. 1335, H. Sharma, M. Saraswat, A. Yadav, J. H. Kim, y J. C. Bansal, Eds., en *Advances in Intelligent Systems and Computing*, vol. 1335. , Singapore: Springer Singapore, 2021, pp. 599-611. doi: 10.1007/978-981-33-6984-9_48.
- [29] P.-F. Lin, M.-T. Lo, J. Tsao, Y.-C. Chang, C. Lin, y Y.-L. Ho, «Correlations between the Signal Complexity of Cerebral and Cardiac Electrical Activity: A Multiscale Entropy Analysis», *PLoS ONE*, vol. 9, n.º 2, p. e87798, feb. 2014, doi: 10.1371/journal.pone.0087798.
- [30] M. Ako *et al.*, «Correlation between electroencephalography and heart rate variability during sleep», *Psychiatry Clin. Neurosci.*, vol. 57, n.º 1, pp. 59-65, feb. 2003, doi: 10.1046/j.1440-1819.2003.01080.x.
- [31] H. Abdullah, N. Maddage, I. Cosic, y D. Cvetkovic, «Brain and heart interaction during sleep in the healthy and sleep apnoea», en *2010 IEEE EMBS Conference on Biomedical Engineering and Sciences (IECBES)*, Kuala Lumpur, Malaysia: IEEE, nov. 2010, pp. 276-280. doi: 10.1109/IECBES.2010.5742243.
- [32] H. Abdullah, N. Maddage, D. Cvetkovic, y H. Abdullah, «Phase synchronization and directional coupling between brain and heart during sleep», en *2012 IEEE-EMBS Conference on Biomedical Engineering and Sciences*, Langkawi, Malaysia: IEEE, dic. 2012, pp. 659-663. doi: 10.1109/IECBES.2012.6498075.
- [33] L. Hu y Z. Zhang, Eds., *EEG signal processing and feature extraction*. Singapore: Springer, 2019.
- [34] E. Idrobo-Ávila *et al.*, «Quality assessment for multimodal biosignals acquired intraoperatively», sep. 2023, doi: 10.3205/23GMDS101.
- [35] D. Zhang *et al.*, «An ECG Signal De-Noising Approach Based on Wavelet Energy and Sub-Band Smoothing Filter», *Appl. Sci.*, vol. 9, n.º 22, p. 4968, nov. 2019, doi: 10.3390/app9224968.
- [36] M.-R. Sofia, S.-O. Juandiego, V.-F. Natalia, S. Nicolai, V.-C. Rubiel, y I.-Á. Ennio, «Analysis of electrocardiographic signals to assess heart rate variability under surgical context: a methodological proposal». Accedido: 15 de mayo de 2024. [En línea]. Disponible en: <https://resolver.sub.uni-goettingen.de/purl?gro-2/142229>
- [37] P. Mukherjee y A. Bakshi, «System for ECG Signal Denoising», en *2020 International Conference on Communication and Signal Processing (ICCSP)*, Chennai, India: IEEE, jul. 2020, pp. 0321-0325. doi: 10.1109/ICCSP48568.2020.9182123.
- [38] L. Kramer, C. Menon, y M. Elgendi, «ECGAssess: A Python-Based Toolbox to Assess ECG Lead Signal Quality», *Front. Digit. Health*, vol. 4, p. 847555, may 2022, doi: 10.3389/fdgth.2022.847555.
- [39] B. Porr, L. Howell, I. Stournaras, y Y. Nir, (18 de febrero de 2023). Zenodo. doi: 10.5281/ZENODO.3353396.
- [40] D. Zhai, X. Bao, X. Long, T. Ru, y G. Zhou, «Precise detection and localization of R-peaks from ECG signals», *Math. Biosci. Eng.*, vol. 20, n.º 11, pp. 19191-19208, 2023, doi: 10.3934/mbe.2023848.
- [41] C. Xie, L. McCullum, A. Johnson, T. Pollard, B. Gow, y B. Moody, *Waveform Database Software Package (WFDB) for Python*. PhysioNet. doi: 10.13026/9NJX-6322.

- [42] J. A. Lipponen y M. P. Tarvainen, «A robust algorithm for heart rate variability time series artefact correction using novel beat classification», *J. Med. Eng. Technol.*, vol. 43, n.º 3, pp. 173-181, abr. 2019, doi: 10.1080/03091902.2019.1640306.
- [43] J. G. Proakis y D. G. Manolakis, *Tratamiento digital de señales, cuarta edición*. Madrid: Pearson-Prentice Hall, 2010.
- [44] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probability & statistics for engineers & scientists: MyStatLab update*, Ninth edition. Boston: Pearson, 2017.
- [45] T. Higuchi, «Approach to an irregular time series on the basis of the fractal theory», *Phys. Nonlinear Phenom.*, vol. 31, n.º 2, pp. 277-283, jun. 1988, doi: 10.1016/0167-2789(88)90081-4.
- [46] A. B. Das y M. I. H. Bhuiyan, «Discrimination and classification of focal and non-focal EEG signals using entropy-based features in the EMD-DWT domain», *Biomed. Signal Process. Control*, vol. 29, pp. 11-21, ago. 2016.
- [47] H. M y S. M.N, *Int. J. Data Min. Knowl. Manag. Process*, vol. 5, n.º 2, pp. 01-11, mar. 2015, doi: 10.5121/ijdkp.2015.5201.
- [48] V. Nasteski, «An overview of the supervised machine learning methods», *HORIZONS.B*, vol. 4, pp. 51-62, dic. 2017, doi: 10.20544/HORIZONS.B.04.1.17.P05.
- [49] «GridSearchCV». [En línea]. Disponible en: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html
- [50] R. Quian Quiroga, A. Kraskov, T. Kreuz, y P. Grassberger, «Performance of different synchronization measures in real data: A case study on electroencephalographic signals», *Phys. Rev. E*, vol. 65, n.º 4, p. 041903, mar. 2002, doi: 10.1103/PhysRevE.65.041903.
- [51] «Data Splitting Strategies». [En línea]. Disponible en: <https://amueller.github.io/aml/04-model-evaluation/1-data-splitting-strategies.html>
- [52] M. V. Kamath, M. Watanabe, y A. Upton, *Heart Rate Variability (HRV) Signal Analysis: Clinical Applications*, 1st ed. Baton Rouge: Chapman and Hall/CRC, 2016.